

일반연구자지원사업 최종보고서(최종본)

| | | | | | | | 양식A101 | |
|--|--------------|--|-------------------------|---------------|-------------------|-------------------|-----------------|------------|
| ① 부처사업명(대) | 기초연구사업 | | | | 보안등급(보안, 일반) | | 일반 | |
| ② 사 업 명(중) | 일반연구자지원사업 | | | | 공개가능여부(공개, 비공개) | | 공개 | |
| ③ 세부사업명(소) | 기본연구 | | | | | | | |
| ④ 과제성격(기초, 응용, 개발) | 기초 | | ④-1 실용화 대상여부(실용화, 비실용화) | | | | 실용화 | |
| ⑤ 과 제 명 | 국 문 | 앙상블 학습 기반의 추천 시스템 개발 | | | | | | |
| | 영 문 | Development of an Ensemble Learning-Based Recommender System | | | | | | |
| ⑥ 주관연구기관 | 서강대학교 | | | | | | | |
| ⑦ 협동연구기관 | | | | | | | | |
| ⑧ 주관연구책임자 | 성 명 | 양지훈 | | | 직급(직위) | 교수 | | |
| | 소속부서 | 컴퓨터학과 | | | 전 공 | 전산학 | | |
| ⑨ 연구개발비 및 참여연구원수 (단위: 천원, M·Y) | | | | | | | | |
| 년 도 | 정부출연금 (A) | 기업체부담금 | | | 정부외 출연금 (B) | 상대국 부담금 (F) | 합계 G=(A+B+E) | 참여 연구원수 |
| | | 현금 (C) | 현물 (D) | 소계 E=(C+D) | | | | |
| 1차년도 | 56,980 | | | 0 | | | 56,980 | 3 |
| 2차년도 | 52,030 | | | 0 | | | 52,030 | 3 |
| 3차년도 | | | | 0 | | | 0 | |
| 4차년도 | | | | 0 | | | 0 | |
| 5차년도 | | | | 0 | | | 0 | |
| 합계 | 109,010 | 0 | 0 | 0 | 0 | 0 | 109,010 | 6 |
| ⑩ 총연구기간 | | 2009. 05. 01 ~ 2011. 04. 30(24개월) | | | | | | |
| ⑪ 다년도협약연구기간 | | 2009. 05. 01 ~ 2011. 04. 30(24개월) | | | | | | |
| ⑫ 당해연도연구기간 | | 2010. 05. 01 ~ 2011. 04. 30(12개월) | | | | | | |
| ⑬ 참여기업 | 중소기업수 | | 대기업수 | | 기타 | | 계 | |
| | | | | | | | 0 | |
| ⑭ 국제공동연구 | 상대국연구기관수 | | | 상대국연구개발비 | | | 상대국연구책임자수 | |
| | | | | | | | | |
| <p>관계 규정과 모든 지시사항을 준수하면서 국가연구개발사업에 따라 수행 중인 연구개발과제의 최종보고서를 붙임과 같이 제출 합니다.</p> <p style="text-align: center;">2011 년 6 월 16 일</p> <p style="text-align: center;">주관연구책임자 : 양 지 훈 (인)</p> <p style="text-align: center;">주관연구기관장 : 송 태 경 (직인)</p> <p style="text-align: center;">교 육 과 학 기 술 부 장 관 귀 하</p> | | | | | | | | |

【주요항목 작성요령】

- ② 공개 가능 여부 : 기초연구사업은 공개를 기본으로 함. 다만, 불가피하게 비공개(평가 용도 이외에는 연구보고서 배포를 제한하는 경우)로 하는 경우 교과부소관 연구개발사업처리규정 제28조제2항에 따라 『연구개발결과 공개제한 요청 사유서』를 작성하여 재단에 공문으로 제출 후, 교과부장관 승인이 난 경우에 한하여 배포제한되고, 이 보고서 양식 <연구내용 및 결과>의 10.기타사항 란에 사유를 명확히 기재하여야 함
- ⑤ 과제명 : 당초 연구과제명(과제명 변경을 재단에서 승인받은 경우는 승인된 과제명)을 기재함
- ⑨ 정부출연금 : 전체 연구기간의 연도별 연구비를 기재, 참여연구원 수 : 연구책임자를 제외한 참여연구원 수 기재
 - 간접비를 제외한 인건비+직접비만 기재
 - 참여연구원 수는 연구책임자를 제외한 이 연구에 참여한 모든 연구인력(연구보조원 포함) 인원수를 기재함
- ⑩ 총연구기간/ ⑪ 다년도협약연구기간 : 연구시작일부터 연구종료일까지 총 연구기간 및 개월 수를 기재함
 ⇒ 2009년 선정 과제 : 2009. 05. 01 ~ 2011. 04. 30(24개월)
 ⇒ 2010년 선정 과제 : 2010. 05. 01 ~ 2011. 04. 30(12개월)

- 전자접수이므로 주관연구책임자 및 주관연구기관장의 서명은 서명은 필요하지 않습니다.
- 셀 보호된 내용 수정 방법 : 해당 셀 선택>마우스 우측버튼 클릭>표셀속성 선택>셀 선택>셀보호 해제

「일반연구자지원사업 협약 연구기간 적용 안내」

| 선정연도 | 연구기간 | 연차 | 과제수 | 총 연구기간 | 다년도 협약기간 | 당해연도 협약기간 | 비고 |
|-------|------|----|-----|-----------------------|-----------------------|-----------------------|----|
| 2009년 | 24개월 | 2 | 630 | 2009.05.01~2011.04.30 | 2009.05.01~2011.04.30 | 2010.05.01~2011.04.30 | |
| 2010년 | 12개월 | 1 | 144 | 2010.05.01~2011.04.30 | 2010.05.01~2011.04.30 | 2010.05.01~2011.04.30 | |

< 목 차 >

I. 연구 계획 요약문

| | |
|-----------------|---|
| 1. 국문 요약문 | 4 |
|-----------------|---|

II. 연구 결과 요약문

| | |
|-----------------|---|
| 1. 국문 요약문 | 5 |
| 2. 영문 요약문 | 6 |

III. 연구 내용

| | |
|---------------------------------|----|
| 1. 연구 개발 과제의 개요 | 7 |
| 2. 국내·외 기술 개발 현황 | 8 |
| 3. 연구 수행 내용 및 결과 | 10 |
| 4. 목표 달성도 및 관련 분야에의 기여도 | 38 |
| 5. 연구 결과의 활용 계획 | 39 |
| 6. 연구 과정에서 수집한 해외 과학기술 정보 | 40 |
| 7. 주관연구책임자 대표적 연구 실적 | 40 |
| 8. 참고 문헌 | 41 |
| 9. 연구 성과 | 42 |
| 10. 기타 성과 | 43 |

〈 연구 계획 요약문 〉

양식 A201

| | | | |
|----------------|---|--------------|----------------|
| 연구의 목적 및 내용 | 추천 시스템은 연구수행 측면에서나 산업적으로 엄청난 부가 가치를 지닌 분야이다. 하지만 기존의 추천 시스템은 희소성(Sparsity), 확장성(Scalability) 문제 등의 고질적인 단점들이 있다. 우리는 이러한 단점들을 해결하고 보다 정확도가 높은 추천 시스템을 개발하기 위해서 최근 각광받고 있으나 아직 국내외의 추천 시스템에 도입되지 못한 다양한 기법들, 특히 행렬기반 알고리즘 및 그래프기반의 알고리즘들을 앙상블 할 것이다. 마르코프 의사결정 프로세스 (Markov Decision Process, MDP) 기반의 앙상블을 통해 전통적 추천 시스템의 고질적인 단점들을 해결한, 보다 범용적이고 효율적으로 적용 가능하며 기존의 시스템 성능을 뛰어넘는 추천 시스템 라이브러리를 개발하는 것이 본 연구의 목표이다. 이 추천 시스템은 특별한 가공 없이도 바로 웹을 통한 전자 상거래를 하는 산업체 등에 바로 적용해 쓸 수 있다. | | |
| 연구결과 | 협력적 여과 (Collaborative Filtering)는 추천 시스템에서 채택하고 있는 대표적 추천 방법이다. 그러나 전통적 Collaborative Filtering은 새로운 사용자 또는 아이템이 끊임없이 등장하는 상황에서 이를 즉각적으로 반영하기가 어렵다. 특히 많은 결측치(Missing Value)를 포함하는 사용자의 데이터는 다루기 어렵기 때문에 거대한 데이터를 다루는 현실세계 문제로의 적용에 많은 제약이 따른다. 본 연구에서는 이와 같은 문제점을 극복하기 위해 SVD(Singular Value Decomposition), MMMF(Maximal Margin Matrix Factorization), NMF(Non-negative Matrix Factorization) 등의 각광 받고 있는 MF(Matrix Factorization) 기법과, 그리고 그래프 기반 추천 시스템 모델 중 가장 성능이 좋다고 알려져 있는 RBM(Restricted Boltzmann Machines) 등을 연구한다. 이러한 추천 시스템들은 모두 2006년에서 2008년 사이 개발된 최신의 기술로 국내에서는 물론 국외에서도 기업에서 이 알고리즘을 이용한 사례는 없다. 우리는 이러한 최신의 기법들을 결합(앙상블, hybridize)하여 시스템 각각이 가지고 있는 단점들을 서로 보완한다. 특히, 기존의 앙상블 학습과는 다르게 각 사용자가 각 아이템에 내린 결정의 순차적 정보를 적용한 MDP 기법을 이용한 앙상블 방법에 대해 연구한다. 알고리즘의 실증적 평가 연구를 위해 Netflix Prize 데이터를 에서 1등을 하고 있고, 세계적인 수준의 추천 시스템을 보유하고 있는 AT&T 연구소와 성능을 비교 평가할 것이다. 최종적으로 완성된 알고리즘을 이용하여 범용적으로 사용 가능한 추천 시스템 라이브러리를 완성한다. | | |
| 연구결과와 활용계획 | 정확도와 유동성 및 확장성이 보장된 새로운 추천 시스템을 도입한 기업들은 자신들의 아이템들을 개수와 종류에 구애받지 않고 최대한 활용하여 매출을 극대화 시킬 수 있다 (예: 영화, 책, 일반 소비재). 사용자의 입장에서서는 보다 정확한 개인화 시스템을 통해 원하는 정보를 찾는 데 필요한 시간 및 비용을 절감할 수 있으며, 더하여 기업의 신뢰도를 높이고 소비 의욕 증진을 통해서 크게는 경제 활성화에 이바지 할 수 있게 된다. 또한 본 연구 과제에서는 데이터 마이닝 뿐만 아니라 통계, 수리적 방법을 기존 추천 시스템과 접목하기 때문에 기초 학문 분야의 응용성을 높이는 데 기여할 수 있다. | | |
| 중심어 | 추천 시스템 | 협력적 여과 | 마르코프 의사결정 프로세스 |
| | 앙상블 학습 | 추천 시스템 라이브러리 | |
| | | | |

〈 연구 결과 요약문 〉

〈한글요약문〉

양식 A202

| | | | |
|-------------------|--|--------------|----------------|
| 연구의 목적 및 내용 | 추천 시스템은 연구수행 측면에서나 산업적으로 엄청난 부가 가치를 지닌 분야이다. 하지만 기존의 추천 시스템은 희소성(Sparsity), 확장성(Scalability) 문제 등의 고질적인 단점들이 있다. 우리는 이러한 단점들을 해결하고 보다 정확도가 높은 추천 시스템을 개발하기 위해서 최근 각광받고 있으나 아직 국내외의 추천 시스템에 도입되지 못한 다양한 기법들, 특히 행렬기반 알고리즘 및 그래프기반의 알고리즘들을 앙상블 할 것이다. 또한 마르코프 의사결정 프로세스 (Markov Decision Process, MDP) 기반의 앙상블을 통해 전통적 추천 시스템의 고질적인 단점들을 해결한, 보다 범용적이고 효율적으로 적용 가능하며 기존의 시스템 성능을 뛰어넘는 추천 시스템 라이브러리를 개발하는 것이 본 연구의 목표이다. | | |
| 연구결과 | 본 연구에서는 SVD(Singular Value Decomposition), MMMF(Maximal Margin Matrix Factorization), NMF(Non-negative Matrix Factorization) 등의 각광 받고 있는 MF(Matrix Factorization) 기법과, 그리고 그래프 기반 추천 시스템 모델 중 가장 성능이 좋다고 알려져 있는 RBM(Restricted Boltzmann Machines) 등을 연구하였다. 이러한 추천 시스템들은 모두 2006년에서 2008년 사이 개발된 최신의 기술로 국내에서는 물론 국외에서도 기업에서 이 알고리즘을 이용한 사례는 없었다. 우리는 이러한 방법들에 콘텐츠 정보를 접목하여 좀 더 나은 성능을 갖는 추천 시스템을 구성하였다. 그리고 여러 최신의 기법들을 결합(앙상블, hybridize)하여 시스템 각각이 가지고 있는 단점들을 서로 보완하려하였다. 우리의 알고리즘은 Netflix 추천시스템 경진대회에서 40,000이상의 참가팀 중에서 130위에 랭크되는 뛰어난 성과를 거두었다. 또한 강화 학습을 사용하여 기존의 추천 시스템을 개량한 방법을 개발하고 앙상블을 통해 더 높은 성능을 획득하였다. | | |
| 연구결과 의 활용계획 | 개발한 새로운 추천 시스템은 콘텐츠에 구애받지 않는 특성으로 국내외 어느 업체에도 적용 가능한 특성이 있다. 정확도와 유동성 및 확장성이 보장된 새로운 추천 시스템을 도입한 기업들은 자신들의 아이템들을 개수와 종류에 구애받지 않고 최대한 활용하여 매출을 극대화 시킬 수 있다 (예: 영화, 책, 일반 소비재). 사용자의 입장에서 보다 정확한 개인화 시스템을 통해 원하는 정보를 찾는 데 필요한 시간 및 비용을 절감할 수 있으며, 더하여 기업의 신뢰도를 높이고 소비 의욕 증진을 통해서 크게는 경제 활성화에 이바지 할 수 있게 된다. 또한 본 연구 과제에서는 데이터 마이닝 뿐만 아니라 통계, 수리적 방법을 기존 추천 시스템과 접목하기 때문에 기초 학문 분야의 응용성을 높이는 데 기여할 수 있다. | | |
| 중심어 | 추천 시스템 | 협력적 여과 | 마르코프 의사결정 프로세스 |
| | 앙상블 학습 | 추천 시스템 라이브러리 | |
| | | | |

〈 SUMMARY 〉

양식 A203

| | | | |
|--------------------------|---|-------------------------------|-------------------------|
| Purpose& contents | <p>Recommender Systems can add huge value in both academic and industrial aspects. However, most of existing systems have problems of sparsity and scalability. To overcome such problems, we will try to harmonize various techniques in the lime lights, yet not introduced in the community, especially matrix-based and graph-based algorithms. In this study, we aim to develop a more universally and efficiently applicable recommender system library on MDP-based-ensemble, which is expected to outperform the current systems.</p> | | |
| Result | <p>We have studied and implemented popular matrix factorization techniques such as SVD(Singular Value Decomposition), MMMF(Maximal Margin Matrix Factorization) and NMF(Non-negative Matrix Factorization), and RBM(Restricted Boltzmann Machines), one of the best graph-based recommender systems. All of those techniques are most up-to-date, developed between 2006 and 2008, and have never been applied in a real system. We also devised a hybrid or an ensemble, of the techniques so they supplement each other's limits and produce improved performance. In addition, we developed an ensemble methodology utilizing Markov Decision Process(MDP). In empirically assessing our algorithm, we benchmarked its performance level to that of AT&T ranked atop at NetflixPrize. As a matter of fact, our recommender system produced outstanding performance ranked 130th among the over 40,000 participants. Finally, we extended our recommender system with reinforcement learning-based ensembles.</p> | | |
| Expected Contribution | <p>We accomplished the followings from our new recommender system with higher accuracy, flexibility and scalability;</p> <ol style="list-style-type: none"> 1. Boosted sales of user companies regardless of their business or the number of their items 2. Saving search time and costs for end-users with more accurately customized system 3. Stronger emotional ties between end-users and service providing companies 4. Contributions to national economy with enhanced monetary circulations 5. Contributions to other basic sciences since the study is based on statistics and other mathematical themes as well as data mining | | |
| Keywords | Recommender System | Collaborative Filtering | Markov Decision Process |
| | Ensemble Learning | Recommender System Library | |
| | | | |

< 연구내용 및 결과 >

양식 A301

- ◎ 1. 연구개발과제의 개요 ~ 10. 중요 연구변경 사항을 항목에 따라 작성함
- ◎ 제목 14point, 소제목 12point, 본문내용은 10point로 작성하며, 줄 간 간격은 조정 가능함
- ◎ 연구내용 및 결과는 50페이지 이내로 작성함
- ◎ 내용 작성과 관련한 설명내용(청색 박스로 표시된 부분)은 내용 작성 시 제거하고 기술함

1. 연구개발과제의 개요

1.1 연구의 필요성

1.1.1 과제 선정 이유

인터넷의 급속한 보급과 더불어, 전자상거래 또는 콘텐츠사이트 기업들이 매우 빠르게 발전해 왔다. 이러한 서비스업체의 양적 팽창에 따라 고객에게는 선택의 기회가 매우 많이 늘어나게 된 반면 기업 간의 경쟁은 매우 치열해 졌다. 특히, 인터넷의 양방향 특성은 기업의 마케팅 전략을 변화시키고 있다. 고객관계관리(Customer Relationship Management, CRM)로 대변되는 이러한 변화는 ‘개인화’를 통해 고객에게 특화된 제품과 서비스를 제공하고자 하는 것이다. 이러한 전략이 성공하기 위해서는 무엇보다 고객의 요구를 정확하게 파악하는 것이 중요하다. 이러한 서비스를 제공하기 위해 제안된 시스템이 바로 추천 시스템(Recommender System, RS)이다.

추천 시스템은 많은 양의 이용 가능한 아이템(item)중에서 사용자(user)의 흥미에 맞는 아이템을 추천해주는 시스템을 말한다. 아이템의 종류는 뉴스나 지식, 음식점 같은 일반 정보에서부터 영화, 음반, 서적, 의류까지 다양한 것들이 될 수 있다. 사용자들은 각각의 아이템에 대해서 다른 선호도를 가진다. 추천 시스템은 이러한 선호도 정보에 기반을 두어 각 사용자에게 맞는 아이템을 추천하게 된다. 사용자의 평가는 직접적 또는 간접적 방법으로 얻을 수 있다. 직접적 방법은 아이템을 접한 사용자가 그에 대해서 직접 평가한 결과를 사용하는 방법으로 영화의 평점을 예로 들 수 있다. 이 방법은 사용자가 평가를 직접 내리기 때문에 정확하고 신뢰성이 있지만, 모든 사용자가 아이템에 평가를 내리기를 기대하기 어렵다. 따라서 아이템을 구매한 기록이나 검색한 횟수 같은 사용자의 기록(log) 분석을 통해 우회적으로 선호도 정보를 얻기도 하는데 이를 간접적 방법이라고 한다. 여기에는 사용자가 아이템을 보는데 소비한 시간이나 마우스 혹은 스크롤바의 동작형태를 분석하는 방법도 사용되었다[1]. 한편, 정확성이 높은 추천 시스템을 개발하기 위해서는 어떤 고객 데이터를 활용할 것인가, 어떤 기법을 사용하여 추천을 수행할 것인가에 대한 연구가 중요하며 사용하는 기법은 높은 정확도와 함께 결측 데이터의 처리, 확장성 등의 관점에서 효과적이어야 한다. 앞으로 전자 상거래뿐만 아니라 많은 비즈니스 부문에서 개인화의 추세는 더욱 가속될 전망이다 만큼, 위의 사항을 반영한, 정확성이 높은 추천 시스템의 개발은 매우 긴요한 과제이다.

2. 국내외 기술개발 현황

2.1 과제 관련 국내외 동향

2.1.1 산업수요 측면

추천 시스템의 산업 수요에 대한 NetRatings[2]의 조사 결과를 살펴보면, 미국의 경우, 구매 전환율 1위부터 7위까지의 인터넷 쇼핑몰이 개인화가 이루어진 사이트였다는 사실을 알 수 있다. 예를 들어, Wall Street Journal(WSJ)[3]의 사이트 리뉴얼에서 가장 중요하게 생각하고 가장 파격적인 변화를 시도한 것이 개인화 부분이다. 더구나, WSJ는 My page를 메인 페이지에 배치하였고, 이 개인화 서비스가 사용자의 특별한 노력 없이 자동적으로 이루어지도록 하였다. 이러한 개인화의 바탕에는 모두 추천 시스템이 중요한 역할을 하고 있다.

아울러, 미국 온라인 도서 구매 사이트 아마존[4], 미국 온라인 DVD 대여 사이트 Netflix[5], 국내 사이트 싸이월드뮤직[6]도 모두 추천 시스템을 사용하고 있다[그림 2-1, 그림 2-2]. 특히 Netflix는 자사가 현재 갖추고 있는 추천 시스템보다 10퍼센트 향상된 성능의 알고리즘 제안에 대해서 100만 달러, 우리 돈으로 14억의 상금을 내걸고 경진대회를 실시하고 있다[7]. 기업이 이윤을 추구하는 집단이고, 아무런 이유 없이 14억이라는 거액을 투자하지는 않을 것이기 때문에, Netflix의 경진대회는 보다 정확한 추천 시스템이 가진 경제적 가치를 보여주는 좋은 예이다. 따라서 이러한 기업의 개인화 요구에 부응하기 위해서는 보다 정확한 추천을 수행할 수 있는 시스템의 개발이 절실히 요구되고 있다.

Hainay, Welcome to Your Amazon.com™ (If you're not Hainay, [click here.](#))



<그림 2-1> 아마존 도서 추천 시스템

거액의 상금이 걸린 Netflix 데이터 마이닝 경진대회가 이 분야에 많은 발전을 가져왔다는 것이 학자들의 생각이다. 150개 국가에서 1만 8천여 팀이 참가하여 각자의 기술을 구현하고 경쟁했기 때문이다. 이 대회 of 결산은 지난해 미국 새너제이에서 열린 2007년 데이터 마이닝 국제 학술회의(KDD 2007)에서 이루어졌고, AT&T 연구소의 Robert M. Bell과 Yehuda Koren이 데이터 마이닝 학술지에 이 내용을 정리해 기고했다[8]. Bell과 Koren은 이 대회에서 최고의 예측률을 보인 모델이 여러 모델을 조합한 모델이라는 점에 우선 주목했다. 모델 조합은 기계 학습 학계가 오래 전부터 연구해 온 분야이다. 배깅(bagging)이나 부스팅(boosting)과 같은 간단한 앙상블 학습에서부터 복잡한 모델 조합법까지, 다양한 방향에서 연구되었다. 실제 데이터베이스

를 대상으로 한 Netflix 연구에서 모델 조합법이 효과를 보였다는 것은 이 기법의 힘을 증명한 것으로, 기계 학습 연구에서 갖는 의미가 크다. 다른 모델의 약점을 서로 보완해주는 방식으로 정확도 향상이 이루어진 것으로 보이기 때문이다.

| 님을 위한 추천음악 | | | | | | |
|---|--|-----------------------|---------|------|-------|------|
| 님이 좋아하실 만한 음악을 추천해 드려요. 추천이유를 클릭하시면 해당 곡이 추천된 이유를 알려드려요. 추천된 곡이 마음에 들면 ♪, 마음에 들지 않으면 ❌를 선택하여 주세요. ❌를 선택한 곡은 다시 추천되지 않습니다. 추천 음악은 어떻게 제공되나요? | | | | | | |
| 듣기 | 소망상자 듣기 | 조르기 | 선풍하기 | 구입하기 | | |
| 번호 | 곡명/앨범명 | 아티스트 | 배경음악 | 추천점수 | 선호도 | 추천이유 |
| 1 | Can't Take My Eyes Off You / His Greatest Love Songs | Engelbert Humperdinck | 선물 구입 | 6.8 | 👍 👎 | 추천이유 |
| 2 | Can't Take My Eyes Off You (By Frankie Valli) / Antology | The Four Seasons | 선물 구입 | 6.8 | 👍 👎 | 추천이유 |
| 3 | 애인...있어요 / Ma Non Tanto | 이은미 | 선물 구입 | 0 | 👍 👎 | 추천이유 |
| 4 | When I First Saw You (Duet) / Dreamgirls | Beyonce, Jamie Foxx | 선물 구입 | 0 | 👍 👎 | 추천이유 |
| 5 | 다행이다 🏆 / 나무로 만든 노래 | 이적 | 선물 구입 | 0 | 👍 👎 | 추천이유 |
| 6 | 들리나오... 🏆 / 베토벤 바이러스 | 태연 | 선물 구입 | 0 | 👍 👎 | 추천이유 |
| 7 | Mad 🏆 / Year Of The Gentleman | Ne-Yo | 선물 구입 | 0 | 👍 👎 | 추천이유 |
| 8 | STRONG BABY (송리솔료) 🏆 / REMEMBER | 빅뱅 | 선물 구입 | 0 | 👍 👎 | 추천이유 |
| 9 | Gone (Feat. 주희-에이트) / Newways Always (GONE) | Dynamic Duo | 선물 구입 | 0 | 👍 👎 | 추천이유 |
| 10 | 입술을 주고 / Sensibility | 백지영 | 선물 구입 | 0 | 👍 👎 | 추천이유 |

<그림 2-2> 싸이월드뮤직 음악 추천 시스템

Netflix의 과감한 데이터베이스 공개와 상금을 건 경쟁 유도도, 데이터 마이닝 분야에서도 상업 자본과 학계의 연구가 서로 필요에 따라 공조하는 좋은 예가 성립되었다. 별 다섯 개의 평점 중 하나를 택해 가장 별을 많이 받은 작품을 내놓는 식의 간단한 응용이 대부분이지만 확실한 수익 모델과 원동력을 가진 자본과, 혁신적인 모델을 계속 추구하며 이론적 기초를 쌓아온 학계의 기계 학습 연구가 상승효과를 일으킨 것이다. 이번 경쟁에서도 추천 시스템 성능 향상에 대한 모델 결합의 효과가 증명되는 소득을 얻었다.

2.1.2 연구수행 측면

추천 시스템에 대해서는 다양한 웹 기반의 시스템들이 제안되고 있으나[1], 시스템에 사용할 정보의 범위, 결측된 정보에 대한 처리, 데이터의 축약을 통한 확장성의 달성 등 여러 측면에서 아직 많은 연구가 필요한 실정이다. 예를 들면, 전자상거래 추천 시스템은 구매 데이터만을 사용하므로 고객의 성향을 정확하게 파악하는 데 한계가 있다. 또한 이런 한계를 극복하기 위하여 구매 데이터 뿐 아니라 고객의 행동패턴을 알 수 있는 부가적인 정보를 파악하여 시스템에 반영한다고 해도 요구되는 정보의 양만큼 결측된 정보, 확장성의 문제 등이 발생하게 된다. 따라서 고객들의 성향을 정확히 파악하기 위해 추천 시스템의 정확도를 높이는 연구와 함께 결측치 처리 및 효율적 계산을 위한 정보 축약을 동시에 수행할 수 있는 알고리즘의 개발에 대한 연구가 국내외에서 절실히 요구되고 있다.

3. 연구수행 내용 및 결과

3.1. 문제 정의

협력적 여과(Collaborative Filtering)는 어떤 아이템에 대해 많은 수의 유저에 의해 주어진 그들의 취향 정보로부터 유저의 선호도를 예측하는 기술이다. 협력적 여과의 기본적인 가정은 어떤 사람이 과거에 어떤 아이템을 좋아한다면, 미래에도 그 아이템을 좋아할 것이라는 것이다. 협력적 여과 기술은 유저에게 그들이 가장 좋아하는 상품을 자동적으로 제안해주는 추천 시스템에 유용하게 쓰일 수 있다.

데이터베이스에는 N 명의 유저와 M 개의 영화에 대한 선호도가 수치적으로 모아져 있다고 가정한다. 예를 들어, 유저는 자신이 본 영화에 대해서 별 한 개에서 별 다섯 개까지 줄 수 있다. 일반적으로 유저는 데이터베이스 안에 있는 모든 영화에 대해서 점수를 매기지 않는다. 단지 유저가 본 영화에 대해서만 점수를 매긴다. 게다가 어떤 유저는 많은 영화를 볼 수도 있고, 어떤 유저는 단지 몇 개의 영화만 볼 수 있다. $V \in R^{N \times M}$ 는 데이터베이스에 모아진 평점 행렬이다. 데이터베이스를 행렬로 표현하면 그림 3-1과 같은 모습이 된다.

| Users | movie | | | | | | | | | |
|-------|-------|---|---|---|---|---|---|---|---|---|
| | | 2 | | 1 | | | 4 | | | 5 |
| | | 5 | | 4 | | | ? | | 1 | 3 |
| | | | 3 | | 5 | | | 2 | | |
| | 4 | | | ? | | | 5 | 3 | | ? |
| | | | 4 | | 1 | 3 | | | 5 | |
| | | | | 2 | | | | 1 | ? | |
| | | 1 | | | | | 5 | 5 | | 4 |
| | | | 2 | | ? | 5 | | ? | 4 | |
| | | 3 | | 3 | | 1 | 5 | | 2 | 1 |
| | | 3 | | | | 1 | | | 2 | 3 |
| | | 4 | | | 5 | 1 | | | 3 | |
| | | | 3 | | | | 3 | ? | | 5 |
| | 2 | ? | | 1 | | 1 | | | | |
| | | | 5 | | | 2 | ? | | 4 | 4 |
| | | 1 | | 3 | | 1 | 5 | | 4 | 5 |
| | 1 | | 2 | | | 4 | | | 5 | ? |

<그림 3-1> 영화 데이터 행렬 표현

$I \in \{0, 1\}^{N \times M}$ 는 인디케이터 함수인데, $I_{ij}=1$ 이면 유저 i 가 영화 j 에 대한 평점을 매겼으면 1이고, 결여되어 있으면 0이다. 행렬 I 는 매우 희소(sparse)하다. 즉 대부분의 행렬의 원소는 결여(missing)되어 있다. V 는 협력적 여과 알고리즘의 훈련 데이터(training data)로 쓰인다. 협력적 여과 알고리즘의 목표는 데이터베이스 내에 결여치(missing values)를 추측해 내는 것이다. $A \in R^{N \times M}$ 는 결여된 평점 데이터가 실제 평점으로 모두 채워진 희소 행렬이자고 하자. 협력적 여과의 성능은 추측 평점과 실제 평점과의 오차로 측정 할 수 있다. 실제 평점은 행렬 A 에 기록되어 있기 때문에 성능평가는 테스트 행렬인 A 를 이용해서 할 수 있다. 행렬 A 는 오차를 계산하는 프로시저에는 알려진다. 예를 들어, A 는 데이터베이스 안에서 최근에 생성된 데이터의 집합으로 구성하거나 랜덤하게 고를 수도 있다.

행렬 A 에 들어간 데이터는 훈련 데이터 V 에서는 제외된다. 오차 계산법으로는 Netflix 경연 대회에서 사용하는 근 평균 제곱 오차(Root Mean Square Error, RMSE)를 사용하였다. $P \in R^{N \times M}$ 는 협력적 여과 알고리즘이

추측한 예측 행렬이라 하자. $J \in \{0, 1\}^{N \times M}$ 는 A 의 인디케이터(indicator) 함수이다. 예측 값 행렬 P 와 실제 값 행렬 사이의 RMSE는 다음과 같다.

$$RMSE(P, A) = \sqrt{\frac{\sum_{i=1}^n \sum_{j=1}^m J(A_{ij} - P_{ij})^2}{\sum_{i=1}^n \sum_{j=1}^m J_{ij}}}$$

3.2. 연구 방향 및 관련 연구

연구 수행에 앞서 다른 연구자들을 통해 구현된 여러 가지 추천 시스템을 살펴볼 필요가 있다. 다른 연구를 살펴보면, 대부분의 추천 시스템은 협력적 여과 또는 콘텐츠 기반의 방법을 사용하고 있다. 협력적 여과는 사용자의 피드백, 즉 주어진 도메인에서 각 아이템에 일정 형식의 평가 점수를 주었을 때의 유형을 다른 사용자와의 유사성이나 차이점을 비교하여, 어떻게 아이템을 추천할 것인가를 결정하는 방법이다. 반면에, 콘텐츠 기반의 방법은 아이템이 가지고 있는 콘텐츠, 그리고 사용자가 가지고 있는 콘텐츠에 대한 흥미도에 기반해서 추천하게 된다. 두 방법은 각자의 장점을 가지고 있지만, 각각의 상황에 따라 알맞은 추천결과를 내지 못하기도 한다. 이를 극복하기 위해, 두 방법들의 이점들을 통합하여 구성하는 추천 시스템 또한 활발하게 연구되고 있다.

본 연구에서는 1차년도에서 먼저 다양한 추천 시스템에 대해 분석하고 이들의 장점을 통합하여(앙상블 기법을 사용) 성능을 향상시키는 연구를 수행하였다. 그 후 2차년도에서는 앙상블에 사용되는 개별 추천 시스템 중 가장 성능이 좋은 방법을 기반으로 하여 이 시스템의 성능을 높이는 연구도 수행하였다. 또한 1차년도와 2차년도에서 살펴본 모든 추천가 시스템을 통합하여 최종적으로 얼마나 좋은 추천 성능을 획득할 수 있는지를 실험적으로 살펴보았다.

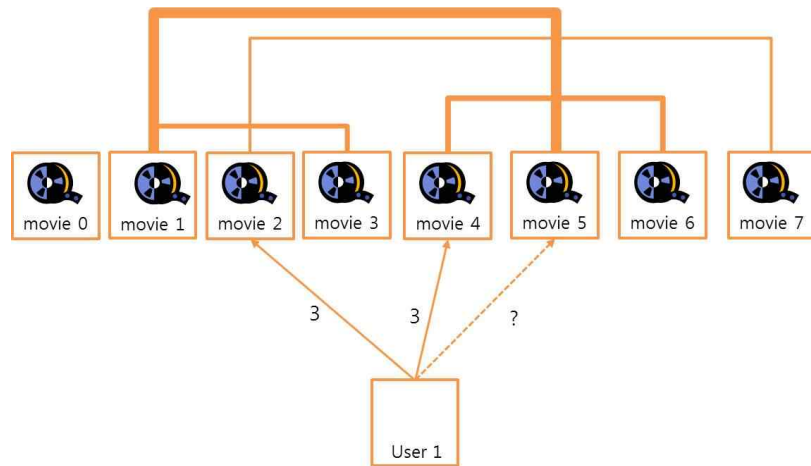
먼저 이 절의 하위 항목으로는 본 연구팀에서 살펴본 여러 가지 추천 시스템의 구조와 원리를 설명한다.

3.2.1. K-최근접 이웃(K-Nearest Neighbor, KNN)

한 유저의 한 영화에 대한 평점을 예측하는 가장 직관적인 방법은 그 영화를 본 다른 유저에게 묻는 것이다. 단순히 전체 영화에 대한 평균으로 예측하는 것이 아니라, 그 유저와 가장 가까운 성향을 가진 유저의 그 영화에 대한 평점을 평균하고 그 결과를 유저에게 제공한다. 이 방법은 K-최근접 이웃(K-Nearest Neighbor, KNN) 알려져 있다. 그림 3-2는 KNN 알고리즘의 개념도이다. 그림에서 각 영화 사이에 여러 굵기로 표시된 선은 영화 사이의 관계(movie/movie correlation)를 뜻한다.

예측해야 할 유저-영화 쌍에 대해서, KNN 알고리즘은 주어진 유저와 가장 비슷한 성향의 K명의 유저를 찾아내고, K명이 주어진 영화에게 매긴 평점을 평균 냄으로써 결과를 도출한다. 반대로, 비슷한 유저를 찾는 것이 아니라 비슷한 영화를 찾아서 K개의 비슷한 영화가 주어진 유저에게 내려진 평점을 평균함으로써 결과를 도출한다. 이렇게 아이템 중심(item-based)의 기법이 Netflix 경연대회에서 더 많이 쓰인다. 왜냐하면 영화의

수는 유저에 비해 상대적으로 작기 때문에 비슷한 유저를 찾는 것보다는 비슷한 영화를 찾는 것이 쉽고 성능이 더 좋다고 알려져 있기 때문이다. KNN 알고리즘은 평점 행렬에 바로 적용할 수도 있고, 다른 알고리즘의 결과물에 대한 후처리 방법으로 사용되기도 한다. KNN 알고리즘의 핵심은 유사도 측정 방법을 어떻게 정의하는가에 있다. 본 연구에서는 협력적 여과에서 가장 많이 사용되는 피어슨 상관 계수와 코사인 측정법을 사용하였다.



<그림 3-2> KNN 알고리즘의 개념도

피어슨 상관 계수는 두 비교대상 간 선형적 관계를 분석하는 방법이다. 두 비교 대상은 서로 독립적인 관계로부터 서로 상관된 관계일 수 있으며, $[-1, 1]$ 사이의 값에 따라 -1 , 1 에 가까울 경우 선형 관계, 0 에 가까울 경우 독립적인 관계에 가깝다고 판단된다. 피어슨 상관 계수는 두 비교 대상간의 연관 관계를 비교적 명확하게 판단할 수 있으므로, 다양한 알고리즘에서 유사도 측정 기법으로 사용되고 있다. 피어슨 상관 계수를 P 라고 할 때, 두 벡터 x, y 사이의 상관 계수는 다음과 같다.

$$P(x,y) = \frac{\sum (x_i - x_{mean})(y_i - y_{mean})}{\sqrt{\sum (x_i - x_{mean})^2} \sqrt{\sum (y_i - y_{mean})^2}}$$

코사인 측정 방법(코사인 유사도, cosine similarity)은 두 벡터 사이의 코사인 각을 찾는 수식을 유사도 함수로 사용한 경우로, 코사인 유사도의 수식은 아래와 같이 두 벡터 사이의 코사인 각을 찾는 공식과 동일하다. $[-1, 1]$ 사이 값을 가지며, -1 에서 1 로 변화할수록 유사성이 크다는 것을 나타낸다. 이를 사용하여 두 비교 대상이 얼마나 잘 결합되어 있는가에 대한 평가를 내릴 수 있다. 수식은 다음과 같이 나타난다.

$$C(x,y) = \cos(\theta) = \frac{\sum x_i \times y_i}{\sqrt{\sum x_i^2} \times \sqrt{\sum y_i^2}}$$

3.2.2. 글로벌 효과(Global Effect)

Netflix 1위 팀인 BellKor은 KNN 알고리즘에 유용한 데이터 정규화(normalization) 기법인 “global effect”라는 기법을 적용했다. Bellkor의 KNN 알고리즘에는 데이터 정규화 단계에서 “글로벌 효과”라고 불리는 효과를

조절하기 위한 처리 기법이 추가된다. 예를 들어 글로벌 효과는 어떤 유저가 특정 영화에 더 많은 평점을 주거나 낮게 주는 경향이 있거나 반지의 제왕 시리즈 영화한테는 비슷한 평점을 주는 효과를 말한다. 또 영화는 처음 개봉 당시에는 높은 평가를 받다가 매우 오랜 시간이 지난 후 낮은 평가를 받을 수도 있다. 어떤 영화는 많은 사람들이 보아서 평점 데이터가 많을 수도 있다. 또 어떤 영화는 많은 사람이 보지 못해서 적은 평점 데이터만 있을 수도 있다. 글로벌 효과는 데이터에서 그러한 효과들을 제거하여 정규화하는 것이다.

이 글로벌 효과는 KNN 알고리즘에서 유용하게 사용됨은 물론이고, 데이터의 내용을 반영하는 척도로서 쉽고 간단하게 추천 시스템을 구성할 수 있는 방법이기도 하다. 다시 말해, 우리는 어떤 유저의 영화에 준 평점의 평균을 구해서 이 유저가 앞으로 볼 영화에 대해 어느 정도의 평점을 줄지를 대략 예측해 볼 수 있다. 이 평균은 각 유저별로 어떤 유저가 다른 유저에 비해 평점을 더 후하게, 또는 더 박하게 주는지를 살펴볼 수 있는 기준이 될 수 있고 그렇기 때문에 다른 추천 시스템의 결과와 결합될 수 있다.

좀 더 구체적으로 설명하기 위해, r_{ui} 를 유저 u 가 영화 i 에 대해 내린 평점이라고 하자. $r_{ui}(N)$ 는 N 개의 글로벌 효과가 사라진 잔차(residual)를 의미한다. 예를 들어서 글로벌 효과의 적용은 다음과 같이 된다.

$$\begin{aligned} r_{ui}(0) &= r_{ui} \\ r_{ui}(1) &= r_{ui}(0) - effect_1 \\ r_{ui}(2) &= r_{ui}(1) - effect_2 \\ &\dots \\ r_{ui}(n) &= r_{ui}(n-1) - effect_n \end{aligned}$$

각 글로벌 효과를 구하는 공식과 실험 결과는 Bellkor팀의 논문에 설명되어 있다[9]. 본 연구팀이 구현한 결과는 Bellkor팀과는 약간 다른데 결과는 표 3-1에 기술하였다.

<표 3-1> 글로벌 효과의 결과


| # | Effect | RMSE |
|-----|----------------------------------|--------|
| #1 | Overall mean | 1.1296 |
| #2 | Movie effect | 1.0527 |
| #3 | User effect | 0.9809 |
| #4 | User×Time(user) ^{1/2} | 0.9806 |
| #5 | User×Time(movie) ^{1/2} | 0.9783 |
| #6 | Movie×Time(movie) ^{1/2} | 0.9764 |
| #7 | Movie×Time(user) ^{1/2} | 0.9754 |
| #8 | User×Movie average | 0.9714 |
| #9 | User×Movie support | 0.9685 |
| #10 | Movie×User average | 0.9675 |
| #11 | Movie×User support | 0.9652 |

3.2.3 제약적 볼츠만 머신(Restricted Boltzmann Machines, RBMs)

협력적 여과를 푸는 제약적 볼츠만 머신(Restricted Boltzmann Machines, RBMs)은 Salakhutdinov가 제안했

다[10]. RBM은 협력적 여과 문제에 대해 절대적인 성능은 SVM에 비해 떨어지지만, 다른 알고리즘과 결합 시 많은 성능 향상을 가져온다고 알려져 있다. 이는 그래프 기반인 RBM이 다른 행렬 인수분해 알고리즘이나 KNN 알고리즘이 보지 못하는 데이터의 양상을 볼 수 있는 능력을 가지고 있기 때문이다.

영화의 개수를 M , 유저수를 N , 평점 범위를 정수 1에서 K 까지라 하자. RBM을 협력적 여과에 적용하는데 생기는 첫 번째 문제는 어떻게 효율적으로 결여 평점(missing ratings)을 처리하는지에 대한 문제이다. 한 유저가 평점을 매긴 영화 평점 데이터를 한 개의 RBM의 훈련 데이터 집합으로 사용했다. 각 RBM은 M 개의 소프트맥스(softmax) 가시 유닛(visible unit)과 이와 대칭적으로 연결된 이진 은닉 유닛(binary hidden unit)로 이루어져 있다. 대부분의 평점은 결여 있기 때문에 한 개의 RBM의 모습은 그림 3-3과 같이 된다.



<그림 3-3> RBM의 구조

모든 RBM은 같은 수의 은닉 유닛을 가지고 있지만, RBM은 단지 유저가 평점을 매긴 가시 유닛만 가지고 있다. 각 RBM은 단지 단일 훈련 데이터 집합만 가지나, 모든 연결 가중치(weight)와 바이어스는 공유한다. 구체적으로 설명하자면, 만일 두 유저가 같은 영화에 대한 평점을 매겼다면, 두 유저의 RBM은 같은 잠재 단위와 가시 단위의 연결 가중치를 사용할 것이다. 하지만 이진 은닉 유닛은 각 RBM마다 각기 따로 가지고 있다. 지금부터 표기를 간단히 하기 위해서, 한 유저의 한 개의 RBM에 초점을 맞추어 설명하겠다. 기본적으로 학습은 경사 강하법에 의해 이루어지는데, 각 유저에 대해 한 개의 RBM의 가중치를 업데이트되고 전체 유저에 대해 평균 내어 짐으로써 학습이 완료된다. T 를 한 유저가 평점을 매긴 영화의 집합이라 하자. V 는 $K \times |T|$ 개의 이진 지시(indicator) 행렬이다. 만약 유저가 영화 i 에 대해 k 점의 평점을 매겼다면 $v_{ki}=1$ 이고 그렇지 않다면 0이다. h 는 잠재 단위의 이진 값이고, 한 유저의 어떤 잠재적인 특성의 발현 여부를 표현한다고 해석할 수 있다. RBM의 모델은 다음과 같이 이루어진다.

$$p(v_i^k = 1 \mid \mathbf{h}) = \frac{\exp\left(b_i^k + \sum_{j=1}^F h_j W_{ij}^k\right)}{\sum_{l=1}^5 \exp\left(b_i^l + \sum_{j=1}^F h_j W_{ij}^k\right)}$$

$$p(h_j = 1 \mid \mathbf{V}) = \sigma(b_j + \sum_{i=1}^m \sum_{k=1}^5 v_i^k W_{ij}^k)$$

$$, \text{ where } \sigma(a) = \frac{1}{1 + \exp(-a)}$$

W_{ij}^k 는 영화 i 의 평점 k 와 잠재 단위의 특성 j 사이의 대칭적인 연결성을 의미한다. b_{ki} 는 영화 i 에 대한 평점 k 의 바이어스이다. b_j 는 h_j 의 바이어스를 의미한다. 가시 단위의 주변 확률 분포는 다음과 같이 정의된다.

$$p(\mathbf{V}) = \frac{\sum_{\mathbf{h}} \exp(-E(\mathbf{V}, \mathbf{h}))}{\sum_{\mathbf{V}', \mathbf{h}'} \exp(-E(\mathbf{V}', \mathbf{h}'))}$$

여기서 에너지 항 E 는 다음과 같이 주어진다.

$$E(\mathbf{V}, \mathbf{h}) = -\sum_{i=1}^M \sum_{j=1}^F \sum_{k=1}^5 W_{ij}^k h_j v_i^k + \sum_{i=1}^M \log Z_i - \sum_{i=1}^M \sum_{k=1}^5 v_i^k b_i^k - \sum_{k=1}^5 h_j b_j$$

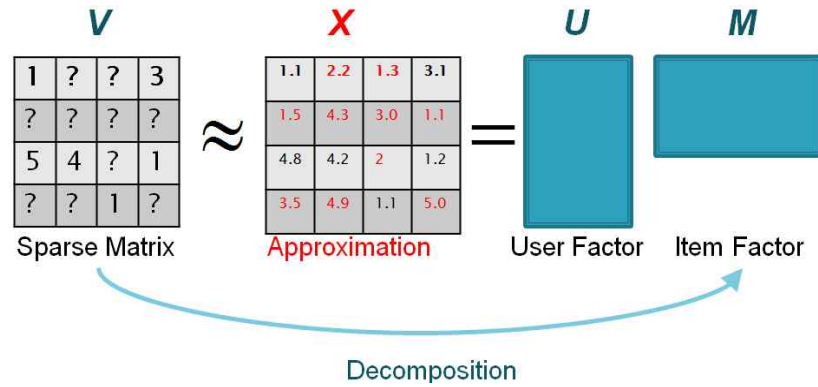
RBM의 학습은 가시 유닛의 로그-우도(log-likelihood)의 가중치에 대한 경사 오름(gradient ascent)으로 이루어진다. 최종적인 업데이트 규칙은 다음과 같이 유도된다.

$$\begin{aligned}
\frac{\partial \log p(\mathbf{V})}{\partial W_{ij}} &= \frac{\frac{\partial p(\mathbf{V})}{\partial W_{ij}}}{p(\mathbf{V})} \\
&= \frac{\sum_{\mathbf{h}} \left(-\exp(-E(\mathbf{V}, \mathbf{h})) \frac{\partial E(\mathbf{V}, \mathbf{h})}{\partial W_{ij}} Z - \exp(-E(\mathbf{V}, \mathbf{h})) \frac{\partial Z}{\partial W_{ij}} \right)}{p(\mathbf{V}) Z^2} \\
&= \frac{\sum_{\mathbf{h}} -\exp(-E(\mathbf{V}, \mathbf{h})) \sum_{\mathbf{V}', \mathbf{h}'} \exp(-E(\mathbf{V}', \mathbf{h}')) \left(\frac{\partial E(\mathbf{V}, \mathbf{h})}{\partial W_{ij}} - \frac{\partial E(\mathbf{V}', \mathbf{h}')}{\partial W_{ij}} \right)}{p(\mathbf{V}) Z^2} \\
&= \frac{\sum_{\mathbf{h}} -\exp(-E(\mathbf{V}, \mathbf{h})) \sum_{\mathbf{V}', \mathbf{h}'} \exp(-E(\mathbf{V}', \mathbf{h}')) \left(-\sum_{i=1}^M \sum_{j=1}^F \sum_{k=1}^5 h_j v_i^k + \sum_{i=1}^M \sum_{j=1}^F \sum_{k=1}^5 h'_j v_i'^k \right)}{p(\mathbf{V}) Z^2} \\
&= \frac{\sum_{\mathbf{h}} \exp(-E(\mathbf{V}, \mathbf{h})) \sum_{i=1}^M \sum_{j=1}^F \sum_{k=1}^5 h_j v_i^k}{\sum_{\mathbf{h}} \exp(-E(\mathbf{V}, \mathbf{h}))} - \frac{\sum_{\mathbf{V}', \mathbf{h}'} \exp(-E(\mathbf{V}', \mathbf{h}')) \sum_{i=1}^M \sum_{j=1}^F \sum_{k=1}^5 h'_j v_i'^k}{\sum_{\mathbf{V}', \mathbf{h}'} \exp(-E(\mathbf{V}', \mathbf{h}'))} \\
&= \sum_{i=1}^M \sum_{j=1}^F \sum_{k=1}^5 h_j v_i^k - \sum_{i=1}^M \sum_{j=1}^F \sum_{k=1}^5 h'_j v_i'^k \\
&= \langle h_j v_i^k \rangle_{\mathbf{V}} - \langle h_j v_i^k \rangle_{\text{model}}
\end{aligned}$$

3.2.4 특이값 분해 모델(Singular Value Decomposition, SVD)

행렬 분해 모델은 여러 가지 모델이 존재하지만, 특이값 분해(Singular Value Decomposition, SVD)는 명확한 평가 또는 관계 정보가 있을 경우, 이를 바탕으로 행렬을 분해하였을 때 암묵적 요인(latent factor)를 잘 정의한다고 알려져 있다[11]. 하지만 전통적인 SVD 풀이법은 결측 정보가 있을 경우, 예를 들어 어떤 사용자가 시청한 영화가 있지만 그것에 대한 평가 정보가 없는 경우, 해결 방법이 정의되어 있지 않다. 이러한 문제로 인해서 추천 시스템에서 사용되는 행렬 분해 모델은 기존의 수학적 방법으로 해결하는 것이 힘들다. 이를 위해 추천 시스템에서 사용되는 행렬 분해 기법 중 하나는 임의의 특성 행렬을 구성하여 관찰된 목표 행렬과의 차이 값을 기울기 강하 기법에서 사용함으로써 특성 행렬을 학습하는 방법이 많이 사용되고 있다[12].

문제를 정의하기 위해, 영화의 개수를 M , 유저수를 N 라 하자. SVD는 완전히 관찰된 목표 행렬(fully observed target matrix) A 와의 합-제곱 거리(sum-squared distance)를 최소화하는 저계수(low-rank) 행렬 $V=UM$ 을 찾는다. 그리고 이 두 행렬 U, M 을 사용하여 V 에 있는 결측치(missing values)를 예측하게 된다. 영화 추천 시스템에서 분해된 특성 행렬 U 와 M 은 각각 사용자와 영화의 특성 벡터로 구성된다. 그리고 이 두 개의 특성 벡터의 내적을 통해 사용자 i 가 영화 j 에 부여한 점수를 예측할 수 있다. 그림 3-4는 이를 표현한 개념도이다.



<그림 3-4> 행렬 인수분해의 개념도

여기서 $U \in R^{N \times k}$ and $M \in R^{N \times k}$ 이고 k 는 특성(feature)의 차원이다. 또한 위에서 설명한 내용을 수식으로 표현하면 다음과 같다.

$$f(U, M) = \sum_{(i,j) \in Y} \underbrace{\left(x_{ij} - \sum_{k=1}^K U_{ik} M_{kj} \right)^2}_{e_{ij}^2} + \lambda \sum_{(i,j) \in Y} \left(\|U_j\|^2 + \|M_j\|^2 \right)$$

수식에 나타난 해 행렬 U, M 을 구하기 위해 경사 강하법(gradient descent)를 사용한다. $f(U, M)$ 의 두 번째 항은 후에 경사 강하법으로 행렬 U, M 을 학습할 때, 과적합(overfitting)을 막기 위한 조정(regulation) 작용을 한다. SVD 알고리즘의 전체 의사 코드는 알고리즘 1에 기술하였다.

SVD algorithm:

1. Do while Probe RMSE decrease
2. for the (i, j) -th element of the matrix V
3. Compute:

$$e_{ij} = A_{ij} - \sum_{k=1}^K U_{ik} M_{kj}$$

4. Compute the gradient of e_{ij}^2 :

$$\frac{\partial}{\partial U_{ik}} e_{ij}^2 = -2e_{ij} \cdot M_{kj}$$

$$\frac{\partial}{\partial M_{kj}} e_{ij}^2 = -2e_{ij} \cdot U_{ik}$$

5. Update the weights and apply regularization (for $k=1..K$)

$$U'_{ik} = U_{ik} + \eta \cdot (2e_{ij} \cdot M_{kj} - \lambda \cdot U_{ik})$$

$$M'_{kj} = M_{kj} + \eta \cdot (2e_{ij} \cdot U_{ik} - \lambda \cdot M_{kj})$$

6. end
-

<알고리즘 1> SVD 알고리즘

3.2.4.1 NSVD1

Paterek은 NSVD1이라는 SVD의 성능을 향상시킨 흥미로운 비대칭 인수 모델(asymmetric factor model)를 제안했다. NSVD1의 가장 큰 특이점은 사용자의 특성 행렬을 대신하여 아이템의 특성행렬을 사용한다는 것에 있다. 보통 한정된 아이템의 수보다, 사용자의 수가 많기 때문에 이런 방법을 사용하면, 다루는 데이터의 크기를 많이 줄일 수 있으며, 더 나아가 성능을 더욱 향상시킬 수 있다는 것을 실험으로 증명하였다[13].

학습해야 될 모수(母數, parameter)는 두 개의 영화 특성 벡터의 집합($W, M \in R^{N \times k}$), 유저 바이어스($b_1, \dots, b_N \in R$), 영화 바이어스($c_1, \dots, c_N \in R$)이다. 유저-영화 쌍 (i, j) 에 대한 예측 평점은 다음과 같이 계산된다.

$$X_{ij} = b_i + c_j + \left(|T_i|^{-0.5} \sum_{k \in T_i} W_k \right)^T M_j.$$

여기서 T_i 는 유저 i 가 본 영화의 집합, $|T_i|$ 는 본 영화의 수가 된다. Paterek은 학습 알고리즘에 대한 세부적인 사항은 기술하지 않았으며 단지 모수가 경사 강하법으로 학습될 수 있다고 기술하였다. 하지만 본 연구팀이 Paterek의 알고리즘을 그대로 구현했을 때는 알고리즘이 제대로 동작하지 않아서, gravity의 제안한 알고리즘을 약간 수정하여 구현하였다. 핵심은 각 유저에 대해서 다음의 새로운 특징벡터 U_i 를 도입하는 것이다. NSVD1의 전체적인 알고리즘은 알고리즘 2에 기술하였다.

$$U_i = |T_i|^{-0.5} \sum_{k \in T_i} W_k.$$

NSVD1 algorithm:

1. Initialize U, M, g
 2. for $u = 1:N$
 3. $U_i = |T_i|^{-0.5} \sum_{k \in T_i} W_k.$
 4. for $k \in T_i$
 5. $e_{ij} = b_i + c_j + \sum_{k=1}^K U_{ik} M_{kj} - V_{ij}$
 6. $g = g + e_{ij} \cdot M_k.$
 7. $M_{kj} = M_{kj} + \eta \cdot (2e_{ij} \cdot U_{ik} - \lambda \cdot M_{kj})$
 8. $b_i = b_i - \eta e_{ij}$
 9. $c_j = c_j - \eta e_{ij}$
 10. end
 11. for $l \in T_i$
 12. $W_l = W_l + |T_i|^{-0.5} g$
 13. end
 14. end
-

<알고리즘 2> NSVD1 알고리즘

Paterek의 NSVD1은 사용자 특성 행렬을 아이템 특성 행렬로 대체하였으며, 이러한 기법의 이점을 정리하면 다음과 같다. 우선, 앞서 언급했듯이 사용자 보다 더 작은 수의 아이템 특성 행렬로 대체하면서 모델의 복잡성을 낮추었고, 새로운 사용자에 대한 확장성도 늘어났다. 또한 어떤 사용자의 특성을 추상화 시킨 특성 벡터를 구성하는 대신, 사용자의 과거의 반응, 즉 사용자가 어떤 영화에 부여한 점수만으로 예측을 시도하기 때문에 기존의 SVD와는 다른 관점으로 데이터의 양상을 살펴 볼 수 있다는 특징이 있다.

3.2.4.2 SVD + NSVD1 = SVD++

SVD와 NSVD1의 업데이트 과정을 합치면 더 좋은 성능의 하이브리드 알고리즘이 만들어진다. 이 알고리즘은 최초 BellKor팀의 Koren이 제안하였고, Netflix의 많은 참가자들에 의해 다른 버전들이 개발되었다. 이 방법은 암시적인 피드백(implicit feedback)이라는 개념을 정의하고, 이를 NSVD1를 이용하여 확장시켰다.

추천 시스템을 학습하기 위해서 사용하는 데이터는 사용자와 아이템 사이의 관계에 대한 정보이다. 사용자가 어떤 아이템을 좋아한다면 높은 점수를 부여할 것이고, 아니라면 그 아이템에 대해 낮은 점수를 부여할 것이다. 이것을 명백한 피드백(explicit feedback)으로 보고, 기존의 알고리즘은 이 정보를 이용해 추천을 하게 된다. 암시적인 피드백은 여기서 더 확장된 개념으로 어떤 사용자가 점수를 부여한 아이템은 사용자와 아이템사이 어떤 관계를 맺을 이유가 있을 것이고, 반대로 점수를 부여하지 않은 아이템에 대해서는 어떤 관계를 안 맺을 이유가 있을 것이다. 이를 어떤 사용자의 암시적인 피드백이라 정의하고, 사용자가 어떤 영화에 부여한 점수는 명백한 피드백과 암시적인 피드백의 요인들이 결합된 결과라고 정의한다. 이러한 개념을 적용하여 기존 모델을 확장할 수 있다. 알고리즘 3은 본 연구팀이 구현한 SVD++ 알고리즘의 의사 코드이다.

| |
|---|
| SVD++ algorithm: |
| 1. Initialize $U \in R^{N \times K}, M \in R^{K \times M}, g \in R^K$ |
| 2. for $u = 1:N$ |
| 3. $U_{i \cdot} = T_i ^{-0.5} \sum_{k \in T_i} W_k.$ |
| 4. for $k \in T_i$ |
| 5. $e_{ij} = b_i + c_j + \sum_{k=1}^K U_{ik} M_{kj} - V_{ij}$ |
| 6. $g = g + e_{ij} \cdot M_k.$ |
| 7. $Y_{ik} = Y_{ik} + \eta \cdot (2e_{ij} \cdot M_{kj} - \lambda \cdot Y_{ik})$ |
| 8. $U_{ik} = U_{ik} + \eta \cdot (2e_{ij} \cdot M_{kj} - \lambda \cdot U_{ik})$ |
| 9. $M_{kj} = M_{kj} + \eta \cdot (2e_{ij} \cdot U_{ik} - \lambda \cdot M_{kj})$ |
| 10. $b_i = b_i - \eta e_{ij}$ |
| 11. $c_j = c_j - \eta e_{ij}$ |
| 12. end |
| 13. for $l \in T_i$ |
| 14. $W_{l \cdot} = W_{l \cdot} + T_i ^{-0.5} g$ |
| 15. end |
| 16. end |

<알고리즘 3> SVD++ 알고리즘

3.2.4.3 커널 능선 회귀를 사용한 SVD의 후처리

Paterek은 또 커널 능선 회귀(kernel ridge regression)를 이용한 SVD의 후처리 방식을 제안했다[12]. $X \in R^{t \times f}$ 를 SVD 알고리즘에 의해 생성된 차원 f 의 특징 행렬이라고 하자. X 의 각 행 x_i 는 한 유저에 의해서 평점이 매겨진 영화의 특징 벡터이다. 즉 t 는 한 유저가 본 영화의 개수다. $Y \in R^{t \times 1}$ 는 회귀 문제의 목적 값(target value)인 그 영화에 대한 실제 평점을 포함하는 벡터이다. 이제 Y 를 답으로 한 X 에 대한 회귀를 할 수 있다. 한 가지 가장 많이 쓰이는 회귀 중에 하나는 능선 회귀이다. 능선 회귀의 가중치 벡터 $w \in R^{t \times 1}$ 는 다음과 같이 구할 수 있다.

$$w = X^T (XX^T + \lambda I)^{-1} Y$$

이제 $K(X, X)$ 를 양의 정부호(positive definite) 행렬로 만드는 커널 함수를 정의하여 적용하면 다음과 같은 커널 능선 회귀 방법이 된다.

$$\hat{y}_i = K(x_i^T, X) (K(X, X) + \lambda I)^{-1} Y$$

커널 함수는 특징 공간을 고차원으로 사상시키는 역할을 해서, 일반적인 능선 회귀가 잡을 수 없는 특징 벡터의 특성을 잡아내는 역할을 한다. Paterek는 커널 함수로는 가우시안(Gaussian) 커널이 협력적 여과 문제에 잘 맞는다고 언급했지만 본 연구팀은 실험을 통해 다항식(polynomial) 커널이 보다 나은 성능을 보여주는 것을 알아냈다.

3.2.5 단일 추천 시스템의 결합(Ensemble Learning)

이전까지 설명한 단일 추천 시스템의 앙상블 학습을 시도할 수 있다. 추천 시스템의 앙상블 학습은 기본적으로 각 단일 추천 시스템들의 회귀 기법(regression)으로 이루어진다. 다음은 앙상블 학습의 구체적인 방법을 단계별로 기술한 것이다.

Step 1. 전체 데이터를 다음과 같이 두 개의 집합으로 나눈다.

| | |
|---------------------|------------------|
| 훈련 집합(Training set) | 검증 집합(Probe set) |
|---------------------|------------------|

Step 2. 각 추천 시스템을 훈련 집합에 대해서 학습한다. 후에 다시 전체 집합에 대해서 다시 학습해야 되기 때문에 검증 집합을 이용해서 각 추천시스템의 매개변수(parameter)를 최적화하고 잘 기록해 둔다. 매개변수에는 학습률(learning rate) 등이 포함된다.

Step 3. 각 추천 시스템이 검증 집합에 대해서 예측하게 한다.

Step 4. 각 추천 시스템이 검증 집합의 실제 평점을 이용해서 예측한 결과로 각 추천 시스템의 가중치를 여러 가지 회귀 기법을 이용해서 학습한다.

Step 5. 전체 데이터로 각 추천 시스템을 다시 학습함으로써, 정확도를 더욱 증가시킨다. 전체 데이터에 대해 다시 학습시키는 이유는 일반적으로 각 추천 시스템은 데이터가 많을수록 정확도가 증가하기 때문이다. 필연적으로 전체 데이터를 통해 다시 학습되어 정확도가 높아진 추천 시스템의 앙상블은 최종 추천 시스템의 정확도를 더욱 올릴 수 있게 해준다.

Step 6. 새로운 데이터에 대해서 예측한다.


다음은 본 연구에서 사용한 회귀 기법들이다.

3.2.5.1 선형 회귀를 이용한 앙상블(Ensemble Using Linear Regression)

처음으로 한 시도는 선형 회귀(linear regression)을 사용하는 것이다. 예를 들어 두 개의 추천 시스템이 예측한 평점을 각각 P_0 , P_1 라 하면 두 개를 결합한 추천 시스템은 다음과 같은 수식으로 표현할 수 있다.

$$P = a_1P_0 + a_2P_1$$

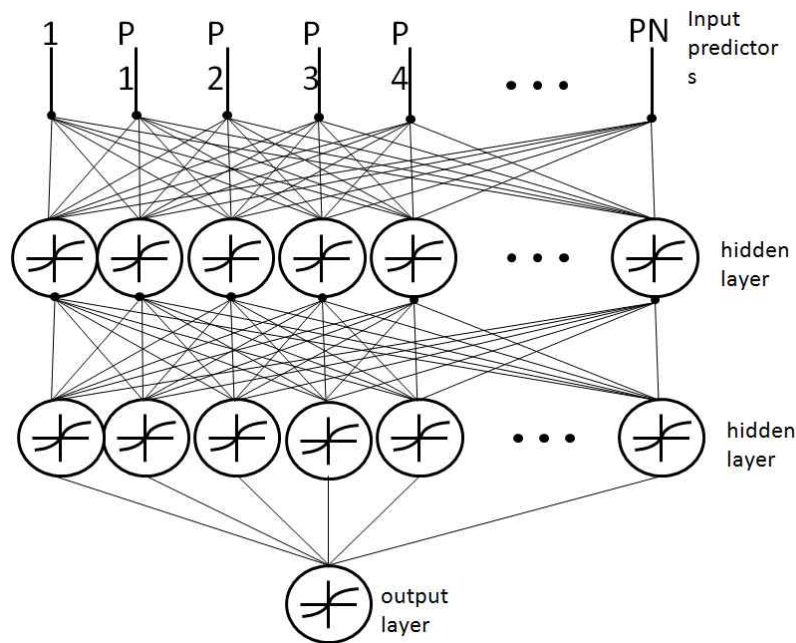
그리고 x 값을 선형 회귀로 구하면 두 개의 추천 시스템을 결합할 수 있다. 그림3-5는 추천 시스템의 선형 회귀를 이용한 앙상블 학습의 개념도이다.



<그림 3-5> 선형 회귀를 이용한 추천 시스템의 앙상블

3.5.1.2 신경 회로망을 이용한 앙상블(Ensemble using Neural Network)

다음으로 시도한 앙상블 학습법은 신경회로망(neural network)을 이용한 학습법이다. 일반적으로 신경회로망은 N 차원의 입력 공간에서 M 차원의 출력 공간으로의 함수에 대한 근사법(function approximator)이다. 신경회로망의 구조는 여러 개의 층이 서로 연결되어 있는 구조이다. 세 개의 층으로 이루어진 신경회로망이라면 입력, 은닉, 출력층으로 구성된다. 추천 시스템의 앙상블을 위한 신경회로망은 그림 3-6과 같은 두 개의 은닉층을 사용하였다. 신경회로망의 학습은 Levenberg-Marquardt 방법을 사용하였다.



<그림 3-6> 신경 회로망을 이용한 추천 시스템 앙상블

3.3 연구 결과

본 연구에서는 위 3.2절에서 설명한 여러 가지 추천 시스템을 기반으로 하여, 다양한 방법으로 새로운 시스템을 구성하고 또 실험을 통해 성능을 검증하였다. 먼저, 1차년도에서는 기존 방법들을 결합하여 성능을 향상시키는 앙상블 방법(위 3.2.5절에서 언급)을 통해 새로운 추천 시스템을 개발하였고, 2차년도에서는 콘텐츠 정보를 고려한 SVD++, SVD++에 유저 성향 정보를 고려하여 MDP를 통해 좀 더 정확한 모델을 구성하는 강화 학습 기반 SVD에 대해 연구하였다. 또한 강화 학습 기반 SVD와 다른 시스템과의 앙상블도 수행하였다.

3.3.1 기존 알고리즘의 앙상블 실험

3.3.1.1 데이터

Netflix사에 따르면 Netflix 경연 대회 데이터는 1998년 10월부터 2005년 12월까지 모은 영화에 대한 평점 데이터이다. 전체 데이터는 480,189명의 유저와 17,770개의 영화에 대한 100,480,507개의 평점으로 이루어져 있다. 검증 데이터로써 100,480,507개의 평점 중 1,408,395개의 평점을 따로 분리해서 사용한다. Netflix 경연 대회는 제공한 데이터와 다른 새로운 데이터에 대한 예측 평점을 요구하고, 제출한 참가자의 RMSE를 측정함으로써 각 참가자의 추천 시스템의 성능을 추천한다. 현재 Netflix사의 추천 시스템은 RMSE 0.9514의 성능을 가지고 있고 자회사보다 10%의 성능 향상의 추천 시스템을 개발한 참가자에게 100만 달러의 상금을 내걸었다. 지금은 대회가 끝났지만 제 2회 Netflix 경연 대회가 있을 예정이다.

3.3.1.2 결과

표 3-2에서 본 연구에서 앙상블 학습에 사용했던 20개의 예측기를 정의했다. 각 K 는 SVD 알고리즘에서는

특성의 수를 의미하고, KNN 알고리즘에서는 이웃의 수를 의미한다.


<표 3-2> 20개의 단일 추천 시스템

| Models | Description |
|-------------|--|
| SVD++100 | $K=100$ |
| SVD++100KRR | $K=100$ with kernel ridge regression |
| SVD++200M | $K=200$ |
| GE | Global effect |
| KNN | $K=20$ |
| SVD600 | $K=600$ |
| SVD++600 | $K=600$ |
| SVD++200KRR | $K=200$ with kernel ridge regression |
| SVD++600KRR | $K=600$ with kernel ridge regression |
| baseline | Movie mean + user bias, simple predictor |
| Movie mean | Movie means |
| SVD1000 | $K=1000$ |
| SVD200 | $K=200$ |
| GE4 | Global effect till #4 |
| GE9 | Global effect till #9 |
| SVD++15 | $K=15$ |
| NSVD80 | NSVD with $K=80$ |
| SVD++256 | $K=256$ |
| NSVD80KRR | NSVD with $K=80$, kernel ridge regression |
| SVD++600B | $K=200$ with user bias |

다음 표 3-3은 앙상블 학습의 결과이다. 표에서, 1행에서 20행까지는 각 모델의 단일 성능을 나타낸다. 21행에서 38행까지는 단일 예측기를 순차적으로 앙상블 했을 때의 RMSE 성능 향상을 보여준다. 선형 회귀를 사용했을 때와 신경회로망을 사용했을 때의 성능 비교도 표에 표시되어 있다. 그림 7을 보면 단일 추천기를 앙상블 시스템에 점차 섞어 갈수록 RMSE가 감소함 즉 성능 향상이 있다는 것을 볼 수 있다. 더욱이 17번 NSVD80의 단일 성능은 .9383 정도로 그리 높지 않은 성능이지만 앙상블 시스템에 추가 됐을 때 가장 큰 RMSE의 감소를 보임을 그림으로 확인할 수 있다. 이것은 단일 추천 시스템의 정확도가 중요한 것이 아니라 기존의 앙상블 시스템이 보지 못하는 데이터의 다른 측면의 앙상을 볼 수 있는 특성의 단일 추천 시스템이 앙상블 시스템에 더 효과적이라는 것을 말해준다. 신경회로망이 선형회귀보다 RMSE 0.0015정도의 성능 향상이 있음을 알 수 있다. 현재까지 구현된 앙상블 추천 시스템의 성능은 Netflix 회사의 추천 시스템보다 약 7~8%의 성능 향상을 이룩하였다. 현재 Netflix 경연대회를 우승한 Bellkor팀이 10%의 성능 향상을 달성하였으므로 아직 세계 최고 수준의 추천 시스템에 비교해서 성능이 약간 부족한 상태이다. 하지만 추가적으로 단일 추천 시스템들이 추가되면 더욱 세계적인 수준에 근접할 것으로 예상되며, 이에 2차년도에서는 새로운 단일 추천 시스템에 대해 연구하였다.

<표 3-3> 추천 시스템 앙상블 결과

| # | model | single performance | |
|----|---------------|------------------------|-------------------|
| 1 | SVD++100 | 0.8939 | |
| 2 | SVD++100KRR | 0.8903 | |
| 3 | SVD++200M | 0.8927 | |
| 4 | GE | 0.9582 | |
| 5 | KNN | 0.9247 | |
| 6 | SVD600 | 0.8980 | |
| 7 | SVD++600 | 0.8914 | |
| 8 | SVD++200KRR | 0.8895 | |
| 9 | SVD++600KRR | 0.8890 | |
| 10 | baseline | 0.9809 | |
| 11 | Movie mean | 1.0458 | |
| 12 | SVD1000 | 0.8993 | |
| 13 | SVD200 | 0.9009 | |
| 14 | GE4 | 0.9771 | |
| 15 | GE9 | 0.9645 | |
| 16 | SVD++15 | 0.9051 | |
| 17 | NSVD80 | 0.9383 | |
| 18 | SVD++256 | 0.8917 | |
| 19 | NSVD80KRR | 0.9135 | |
| 20 | SVD++600B | 0.8906 | |
| | | Linear blending | NNblending |
| 21 | 1+2+3 | 0.8883 | 0.8868 |
| 22 | 1+2+3+4 | 0.8866 | 0.8851 |
| 23 | 1+2+3+4+5 | 0.8863 | 0.8848 |
| 24 | 1+2+3+4+5+6 | 0.8859 | 0.8844 |
| 25 | 1+2+3+4+5+6+7 | 0.8852 | 0.8837 |
| 26 | 1+2+...+8 | 0.8849 | 0.8835 |
| 27 | 1+2+...+9 | 0.8848 | 0.8833 |
| 28 | 1+2+...+10 | 0.8840 | 0.8825 |
| 29 | 1+2+...+11 | 0.8839 | 0.8825 |
| 30 | 1+2+...+12 | 0.8838 | 0.8825 |
| 31 | 1+2+...+13 | 0.8838 | 0.8824 |
| 32 | 1+2+...+14 | 0.8838 | 0.8824 |
| 33 | 1+2+...+15 | 0.8837 | 0.8823 |
| 34 | 1+2+...+16 | 0.8837 | 0.8822 |
| 35 | 1+2+...+17 | 0.8816 | 0.8801 |
| 36 | 1+2+...+18 | 0.8813 | 0.8798 |
| 37 | 1+2+...+19 | 0.8812 | 0.8797 |
| 38 | 1+2+...+20 | 0.88113 | 0.8797 |

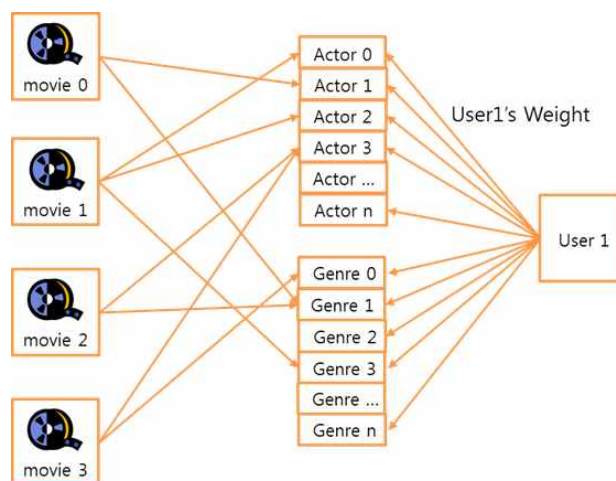


<그림 3-7> 앙상블 학습의 효과

3.3.2. SVD와 콘텐츠 정보의 결합

콘텐츠 기반의 필터링은 앞서 살펴본 모델들과는 달리, 사용자나 영화에 대한 프로필을 생성하여, 해당 프로필은 기반으로 사용자와 영화, 또는 각각의 선호도를 예측한다[14]. 이를 위해서는 이를 위해서는 각 사용자나, 아이템의 속성을 파악할 필요가 있다. 예를 들어 영화의 속성은 영화감독, 배우, 장르 등이 있으며, 어떤 사용자가 영화감독 A가 찍은 영화를 좋아 한다면, 영화감독 A의 다른 영화를 추천 해주는 방법이 콘텐츠 필터링의 가장 간단한 기법이다.

조금 더 일반적인 콘텐츠 기반 필터링에서는 각 사용자별로 흥미 있어 하는 속성과 각 속성에 대한 가중치 정보를 유지하고, 이를 기반으로 추천을 하게 된다. 어떤 사용자에게 높은 가중치를 가지는 속성이 많이 포함된 아이템일수록 추천될 비율이 높아질 것이다. 그림 3-8은 콘텐츠 기반 필터링의 예를 나타낸 것이다. 이 가중치를 사용자와 영화 사이의 숨겨진 관계라고 할 때, 이 관계를 학습하는 것이 콘텐츠 기반 필터링의 중요한 목적이 된다.



<그림 3-8> 콘텐츠 기반의 필터링

즉, 콘텐츠 정보를 이용하여 어떤 사용자 i 가 영화 j 에 대한 숨겨진 관계들을 찾아내기 위해 3.2.4절에서 설

명한 경사 강하 기법을 이용하여 학습하는 SVD를 확장한다.

3.3.2.1 콘텐츠 기반 SVD++

우선 사용자와 콘텐츠 사이의 경향성을 파악하기 위해 행렬 형태로 관계를 표현한다. 이를 위해 구성한 행렬은 다음과 같다.

$$A_{contents} = \begin{cases} A_{contents}(n,c) = 1, & \text{if movie } n \text{ has contents } c \\ A_{contents}(n,c) = 0, & \text{otherwise} \end{cases}$$

이렇게 구성된 행렬을 SVD를 이용하여 각 사용자의 콘텐츠에 대한 경향성과 콘텐츠의 경향성을 표현하면 아래 식과 같다. C 는 콘텐츠를 속성값들로 나타냈을 때 속성의 총 가짓수이다.

$$A_{contents} \cong \tilde{A}_{contents} = YH, (Y \in R^{N \times k}, H \in R^{k \times C})$$

Y 는 사용자의 특성행렬, H 는 콘텐츠의 특성행렬이 된다. 하지만 사용자가 부여한 영화의 점수를 예측하는 것이 목표이므로 위의 공식을 그대로 사용할 수는 없다. 영화와 사용자 사이의 관계를 예측하기 위해 사용자와 콘텐츠의 특징 행렬을 이용하여 $R^{M \times N}$ 행렬의 결과가 나오도록 수정해 줄 필요가 있다. 이를 위해서 위 수식을 수정한 아래의 수식을 이용하여 학습한다.

$$A \cong \tilde{A} = Y(|R_j|^{-0.5} \sum_{c \in R_j} H_c)$$

수식에서, A 는 사용자와 영화의 관찰된 목표 행렬이고, \tilde{A} 는 모델에 의해 예측되어진 사용자와 영화의 관계 행렬이며, R_j 는 영화 j 에 포함된 콘텐츠 집합을 뜻한다. 위 수식은 영화 i 에 포함된 콘텐츠 특성 벡터의 합을 영화 특성 벡터 대신 사용한다. 행렬의 학습에서 사용자 특성 벡터와 함께 콘텐츠의 특성 벡터가 함께 사용되므로, 사용자와 콘텐츠 사이의 경향성을 파악할 수 있다.

콘텐츠 정보는 완벽하지 않다. 즉 콘텐츠 정보가 담겨 있지 않을 경우, 위의 공식을 그대로 사용하면 어떤 정보도 수집하지 못한 영화는 학습이 불가능 하다. 이러한 경우를 처리하기 위해 기준선 추정 기법을 추가한다. 기준선 추정 기법은 어떤 사용자가 다른 사용자들에 비해 높은 점수를 잘 주거나, 또는 어떤 영화가 다른 영화들에 비해 낮은 점수를 많이 받았던 기록이 있을 경우, 이러한 각 사용자, 영화의 경향성을 반영한다. 즉 점수 평균으로부터 각자의 편향성을 반영한다. 그래서 수식에 이를 추가하면 아래와 같다. 여기서 B 는 바이어스를 뜻하며 보통 영화의 점수 평균을 사용한다. 이 바이어스를 기준선 추정으로 추가함으로써, 콘텐츠를 정보를 얻지 못한 영화에 대해서도 다른 사용자의 경향성을 이용하여 학습이 가능하다.

$$A \cong \tilde{A} = B + Y(|R_j|^{-0.5} \sum_{c \in R_j} H_c)$$

이를 위에서 설명한 SVD++에 결합하기 위해, 콘텐츠 행렬 H 를 SVD++에서 같이 학습할 수 있다. 이를 반영한 알고리즘의 의사 코드는 다음과 같다.

Contents based SVD++ algorithm:

1. **Initialize** $U \in R^{N \times K}, M, W, C \in R^{K \times M}, g \in R^K$
 2. **for** $u = 1:N$
 3. $U_{i \cdot} = |T_i|^{-0.5} \sum_{k \in T_i} W_k + |R_j|^{-0.5} \sum_{c \in R_j} H_c.$
 4. **for** $k \in T_i$
 5. $e_{ij} = b_i + c_j + \sum_{k=1}^K U_{ik} M_{kj} - V_{ij}$
 6. $g = g + e_{ij} \cdot M_k.$
 7. $Y_{ik} = Y_{ik} + \eta \cdot (2e_{ij} \cdot M_{kj} - \lambda \cdot Y_{ik})$
 8. $U_{ik} = U_{ik} + \eta \cdot (2e_{ij} \cdot M_{kj} - \lambda \cdot Y_{ik})$
 9. $M_{kj} = M_{kj} + \eta \cdot (2e_{ij} \cdot U_{ik} - \lambda \cdot M_{kj})$
 10. $b_i = b_i - \eta e_{ij}$
 11. $c_j = c_j - \eta e_{ij}$
 12. **end**
 13. **for** $l \in T_i$
 14. $W_{l \cdot} = W_{l \cdot} + |T_i|^{-0.5} g$
 15. **end**
 16. **for** $c \in R_j$
 17. $H_c = H_c + |R_j|^{-0.5} g$
 18. **end**
 19. **end**
-

<알고리즘 4> 콘텐츠 기반 SVD++ 알고리즘

3.3.2.2 데이터

데이터는 MovieLens 데이터[15]를 사용하였다. 이 데이터에는 다양한 콘텐츠 정보가 포함된다. 표 3-4와 3-5는 데이터의 특성을 나타낸 것이다. 점수는 1점에서 5점 사이에서 0.5점 단위로 이루어져 있다. 사용자가 부여한 점수는 전체 관계에서 1.3%에 해당하므로, 매우 희박하다는 데이터 특성을 가지고 있다. 또한 데이터에는 100,000개의 태그 정보와 20개의 장르 정보가 함께 포함되어 있다.

<표 3-4> MovieLens 실험 데이터

| | | |
|-----------|--------|------------|
| MovieLens | Movies | 10,681 |
| | Users | 71,567 |
| | Rating | 10,000,054 |

이러한 데이터를 기초로 웹 콘텐츠 사이트 API를 이용하여 콘텐츠 데이터를 함께 구성하였으며, 배우, 감독 등의 정보를 추가 시켰다. 콘텐츠 정보들은 한 영화당 10개 이하의 관계를 가지기 때문에 앞서 기본이 되는 무비렌즈 데이터에 비해 더욱 희박하다는 특성을 가진다.

장르, 태그 정보 외 부가 정보를 추가시키기 위해 사용한 웹 API는 네이버 개발자 센터에서 제공하는 영화

API[16]와 다음 DNA에서 제공하는 영화 콘텐츠 API[17]를 사용하였다. 우선 무비렌즈에서 제공하는 데이터를 이용하여 웹 API에 쿼리를 날려 받은 XML문서를 분석, 데이터에 추가시키는 방식으로 구현하였으며, 쿼리를 생성하기 위해 영화의 영문 제목 및 제작 연도를 이용하였다.

데이터 생성을 위해 사용한 웹 API의 경우 한국에서 개봉된 영화의 정보를 우선으로 하기 때문에 검색이 되지 않는 경우가 많았으며, 영화 제목이 'Seven'과 같이 짧고 많이 사용되는 경우, 웹 API에서 연관어 검색으로 인해 API 출력 결과에서 영문 제목을 이용해 똑 같은 영화 제목일 경우 해당 영화라고 판단하였다. 이런 경우, 영화 제목이 국내에서 개봉될 때, 제목이 바뀌는 경우 검색이 안 될 때가 많았다. 이렇게 검색이 되지 않는 경우나, 정확히 얻고자 하는 영화인지 판단이 애매할 경우 사용될 데이터에 포함시키지 않았다. 이렇게 해서 생성된 데이터는 원래 MovieLens에 포함된 장르 및 태깅 정보와 감독, 배우, 제작국가에 대한 정보를 포함시켰다.

<표 3-5> 콘텐츠 실험 데이터


| Content information | Contents name | 클래스수 | 레코드수 |
|------------------------|---------------|--------|--------|
| | Tag | 16,529 | 95,580 |
| | Genre | 20 | 21,564 |
| | Director | 3,801 | 9,867 |
| | Actor | 10,203 | 27,410 |

표 3-5는 생성된 데이터에 담겨져 있는 클래스의 수와 레코드 수를 표현한 것이다. 실제 만들어진 데이터를 살펴보면, 영화감독, 출연 배우의 경우 한 영화당 1~2 개의 관계만이 생성되어 있으므로 희소 행렬(sparse matrix)가 생성된다. 영화-컨텐츠의 전체 행렬과 비교해 볼 때, 대략 0.001%의 관계만이 관찰된다.

3.3.2.3 결과 및 분석

알고리즘에서 매개변수들의 최적값을 찾아내는 방법은 실험적인 방법뿐으로 매우 어렵다. 매개변수의 최적값을 찾기 위해 반복적인 실험을 통해 매개변수 값을 수정하였으며, 학습 속도에 상관없이 가장 낮은 RMSE값을 찾는데 중점을 두었다. 알고리즘 4에서의 λ 값들을 각 업데이트 식에 따라 다르게 할당하였는데, 실험적으로 찾은 매개 변수 설정값은 일반적으로 0.001에서 잘 동작하였다.

또한 SVD는 기본적으로 차원 K 라는 중요한 매개변수를 가진다. 차원은 숨겨진 요인에 대한 반영치로 차원의 수가 너무 많아질 경우 과적합 문제가 일어나고, 차원의 수가 너무 적어질 경우 잠재 요인을 모두 학습할 수 없게 되고, 제대로 된 성능을 발휘 할 수 없게 된다. 적합한 차원 K 또한 실험적인 방법을 이용하였으며, 통합 모델의 실험 결과는 그림 3-9와 같다. 차원을 높일수록 RMSE가 증가하였으나, 차원의 개수가 40을 넘어가면서 학습되는 시간에 비해 얻을 수 있는 성능의 향상이 미미했다. 이러한 점을 고려하여 차원 K 의 개수는 40으로 설정하고 성능 평가를 시도하였다.



<그림 3-9> 학습 차원의 개수에 따른 RMSE 변화

먼저 학습 시간을 분석한 결과는 다음 표 3-6과 같다. 각 시간은 1회 학습에 걸린 시간이다. SVD++는 사용자가 점수를 부여하지 않은 모든 아이템들에 대해 업데이트를 시도하기 때문에 시간 복잡도는 $O(R \times N \times K)$ 와 같다. 통합 모델의 경우, 아이템에 포함된 콘텐츠의 특성 벡터를 업데이트하는 과정이 추가되므로, 시간 복잡도는 $O(R \times K \times (N + C))$ 와 같지만, 실제로 콘텐츠에서 관찰되는 관계의 개수는 앞서 언급했듯이 매우 희박하다. 실제로 대부분의 아이템에서 10개 이하의 관계만이 관찰되므로, 콘텐츠의 크기에 따른 변화보다는 평균 콘텐츠 내에서 발견되는 관계들의 비율과 학습 데이터의 양에 따른 차이가 크다.

<표 3-6> 학습 시간 비교

| Algorithm | Learning Time (Sec) |
|-------------------------|---------------------|
| SVD++ (k=30) | 2.89 |
| SVD++ (k=40) | 3.15 |
| SVD++ (k=50) | 3.99 |
| Integrated Model (k=30) | 30.12 |
| Integrated Model (k=40) | 39.24 |
| Integrated Model (k=50) | 47.90 |


성능 평가를 위해 선택한 RMSE값은 5-폴드 교차 검증(5-fold cross validation)을 이용 하였다. 5-폴드 교차 검증의 실험 결과로 나온 5개의 값의 평균을 이용하여 표 3-7에 기록하였으며, 학습 횟수에 따른 RMSE변화는 그림 3-10과 같다. 콘텐츠 정보는 통합 모델 및 콘텐츠 모델에서만 사용하였다.

<표 3-7> RMSE 성능 평가

| Algorithm | RMSE (Root Mean Squared Error) |
|------------------|--------------------------------|
| BaseLine | 0.8786 |
| SVD | 0.7760 |
| Contents Model | 0.8643 |
| SVD++ | 0.7736 |
| Integrated Model | 0.7729 |

표에서 BaseLine은 기준선 예측만을 사용한 결과로, 학습 데이터에서 단순 계산으로 사용자와 영화 바이어스

를 구하였다. 이렇게 생성된 바이어스를 이용하여 테스트한 결과로 알고리즘의 최저 성능의 기준치이며, SVD를 제외한 다른 알고리즘들의 초기 값으로 사용된다. 콘텐츠 모델은 BaseLine과 콘텐츠 정보만을 이용한 알고리즘으로 다른 알고리즘에 비해 성능이 많이 떨어지는 것을 확인 할 수 있다. 이 결과는 콘텐츠 정보에서 많은 부분이 오히려 노이즈로 작용한다는 것을 확인 할 수 있다.



<그림 3-10> 알고리즘별 RMSE 변화

그림 3-10에서 보이듯이, SVD와 SVD++, 그리고 통합모델은 학습 횟수와 차원의 개수를 늘리면 늘릴수록 성능의 차이가 줄어들며, 콘텐츠 모델의 경우 학습이 잘 이루어지지 않는 것을 알 수 있다. 콘텐츠만을 이용한 모델은 데이터의 희소성, 노이즈 문제 등으로 성능이 떨어지지만, 기존의 데이터와 함께 협력적 여과에 적용함으로써, 사용자와 영화 사이의 관계 예측에 도움을 주는 특성을 반영 할 수 있음을 알 수 있다.


본 방법은 SVD++ 알고리즘과 통합하는 과정을 통해, 콘텐츠 정보를 비롯하여, 사용자-영화 사이의 관계를 통합적으로 고려할 수 있는 통합 모델을 제안한 것이다. MovieLens 데이터와 직접 생성한 데이터를 이용한 실험 결과, SVD++ 및 기타 알고리즘에 비해서 성능상 우월하다는 것을 보였다. 수행 시간 문제 및 양질의 콘텐츠 기반 데이터 습득 문제만 해결된다면 충분히 좋은 추천 시스템으로 작동할 수 있을 것이라 생각된다.

3.3.3. 강화 학습 기반 협력적 여과(Reinforcement Learning approach for Collaborative Filtering)

강화 학습(reinforcement learning)은 행동 심리학에 영감을 받은 것으로, 에이전트(agent)가 주어진 환경(environment) 안에서 어떻게 행동(action)을 취했을 때 장기적으로 얻을 수 있는 누적된 보상(reward)가 최대화될 수 있는지에 대해 연구하는 컴퓨터 과학에서 기계 학습 분야의 한 영역이다[18].

기계 학습 측면에서 강화 학습과 일반 학습, 즉 지도 학습(supervised learning)과의 차이는 다음과 같다. 지도 학습에서는 입력과 출력 쌍을 훈련 집합으로 하여 시스템을 학습시켰을 때 그 시스템이 어떤 입력이 주어졌을 때 원하는 해답을 출력할 수 있도록 훈련 집합에서 실제 해답과 시스템이 예측하는 해답의 차이, 즉 오류(error)를 최소화하는 방향으로 학습을 진행한다. 그러나 강화 학습에서는 주어진 환경(상황, state)에서 어떤 행동을 했을 때 얻을 수 있는 보상을 정의한 후 시스템을 작동하여, 지속적인 입력을 통해 입력에 맞는 행

동을 출력하면서 이 행동에 대한 보상이 최대화될 수 있도록, 어떤 상황에서의 가장 좋았던 행동을 학습하게 하고 좋지 않았던 행동을 지양하도록 한다. 이렇게 학습을 수행하는 과정을 그림으로 나타내면 그림 3-11과 같다.



Objective: get as much reward as possible

<그림 3-11> 강화 학습 개념도

강화 학습은 이와 같은 특성으로 인해, 지속적이고 동적인 시스템에서 시스템의 의사 결정을 모델링하고 이를 최적화시키는 여러 문제에 효율적이라고 알려져 있다. 일단 문제를 정형화하면 알려진 계산 과정으로 해결할 수 있기 때문에 다양한 분야에 사용된다. 강화학습은 보행 로봇의 이동, 헬기의 자동 비행, 네트워크 라우팅, 마케팅 전략 선택, 웹 인덱싱 등 많은 분야에서 효율적이라고 알려져 있다.

그러나 본 연구팀이 아는 바로는 협력적 여과 문제를 강화 학습 방식으로 해결한 연구는 아직(2차년도 당시)까지 없었다. 따라서 강화 학습을 사용하여 시스템을 구성하고 이를 실험적으로 검증하였다.

3.3.3.1 문제 정형화(Problem Formulation)

문제를 정형화하기 위해서는 지금 해결하려는 문제가 현재 존재하는 어떤 수학적, 과학적 모델에 적합한 형태로 변형될 수 있는지, 또 어떤 모델을 적용하기에 적합한지에 대한 고찰이 필요하다. 강화 학습을 추천 시스템 구성에 적용하기 위해서, 우리는 학습의 강화 요소, 즉 어떤 사람이 어떤 아이템에 대해 평점을 내리는데 있어서 이전의 경험이 이후의 결정에 영향을 미치는지, 그렇다면 그 경험이 어떤 행동을 강화하거나 어떤 행동을 약화시키는지, 이러한 것들이 현상적으로 나타나는지에 대해 생각하여야 한다. 그리고 이것이 모두 해당된다면 해당되는 요소들을 어떻게 과학적으로 모델링할지를 고려하고 문제를 해결할 수 있다.

본 연구팀은 이른바 잔상 효과(persistence of vision)의 개념을 사용자의 아이템 평가 양상에 적용시킴으로써 이를 강화 학습 기법을 사용할 수 있는 문제로 보았다. 잔상 효과란, 어떠한 빛의 자극이 눈에 들어왔다가 제거되었을 때 시각기관에 이에 대한 흥분상태가 계속되어 잠시 시각작용이 남는 경우를 뜻하는 용어이다. 이 잔상효과가 유저가 영화, 음악 등을 평가할 때에도 나타날 수 있다고 가정할 수 있다. 예를 들어 어떤 유저가 재미없는 영화 A를 보고 난 후 영화 B를 보았을 때의 평점과 재미있는 영화 C를 보고 난 후 영화 B를 보았을 때, 유저가 내린 영화 B에 대한 평점은 다를 것이라고 예상할 수 있다. 즉, 현재 어떤 영화의 평점을 매겨야 한다면 이전에 본 영화가 지금 내려야 할 결정에 영향을 끼칠 수 있다. 이전에 본 아이템에 대한 관찰(observation)을 어떤 상태(state) 또는 환경(environment)로 간주했을 때, 나의 행동은 현재 본 아이템에 어떤 평점을 내릴 것인가 하는 것으로 정의된다. 그리고 이 결정에 대한 보상이 정의된다면 이 문제는 전형적인 강화 학습 문제의 형태를 지닐 것이다. 이에 착상하여, 잔상 효과처럼 사용자의 아이템에 대한 평가의 순서가 사용자의 결정에 끼치는 영향을 수학적으로 모델링하기 위해 본 연구팀은 강화 학습 기법을 협력적 여과 문제

에 적용하였다.

본론으로 들어가서, 협력적 여과 문제를 강화 학습 기법으로 접근한 제안 알고리즘을 설명하기 위해서는 일단 협력적 여과 문제를 마르코프 결정 과정(Markov Decision Process, MDP)으로 정형화해야 한다[19]. 마르코프 결정 과정은 순차적 결정 문제에 대한 수학적 틀을 제공한다. 협력적 여과문제는 다음과 같이 MDP의 5개 구성 요소로 정의 될 수 있다.

- 상태 (State) S : 영화의 평점이 상태가 정의된다. 1부터 K 까지 평점을 매길 수 있다면 상태의 크기 $|S|$ 는 K 개다. $s_t^{(i)} \in S$ 는 유저 i 가 t 번째 본 영화의 평점이 된다.
- 행동(Action) A : 앞서 정의 했듯이 상태 s_t, s_{t+1} 는 각각 t 번째와 $t+1$ 번째로 본 영화의 평점이 된다. 유저 i 가 t 번째 영화에 대해 평점 s_t 를 내리고 그 다음 본 영화에 대해서 s_{t+1} 의 평점을 매김으로써 상태가 전이하는데 이러한 상태 전이를 행동 $a_t^{(i)} \in A$ 로 정의한다.
- 전이 확률(Transition Probability) : 협력적 여과에 대한 MDP는 결정적(deterministic) MDP라고 가정한다. 즉 현재 상태 s_t 에서 현재 행동 a_t 를 취했을 때 다음 상태 s_{t+1} 는 랜덤이 아니다. (확률 1)
- 할인율(Discount factor) $\gamma : 0 < \gamma < 1$ 로 설정한다.
- 보상(Reward) r : 유저가 상태 s_t 에서 행동 a_t 를 취해서, 다음 상태 s_{t+1} 로 전이했을 때, 유저는 보상 또는 벌칙(penalty)를 받는다. 만약 상태를 평점으로 정의한다면, 보상 함수 r 은 수식 (#)과 같이 정의된다.

$$r(s_t, a_t) = s_{t+2} - \text{predictor}(i, j)$$

여기서 $\text{predictor}(i, j)$ 는 유저 i 의 영화 j 에 대한 어떤 예측기의 예측 평점을 의미한다. 본 논문에서는 이를 기본 예측기(base predictor)로 부른다. 예를 들어 영화 j 을 평균 평점이나 SVD 예측기의 예측 평점이 될 수 있다. 다음다음 상태 s_{t+2} 는 각 유저가 본 일련의 영화에 대한 평점 데이터를 통해 알 수 있다. 상태를 평점으로 정의할 때 왜 다음다음 상태 s_{t+2} 를 이용하는지에 대해서는 다음 절에서 자세히 설명한다.

위 다섯 가지 요소가 정의되었을 때, 정책(policy)와 벨류 함수(value function)을 정의할 수 있다.

정책(policy) $\pi: S \rightarrow A$ 는 각 상태 S 에서 행동 A 로의 사상(mapping)이다. 시작 상태 s_0 와 정책 π 가 주어지면, 벨류 함수(value function) $V^\pi(s_0)$ 는 다음 수식과 같이 정의된다. 벨류 함수 $V^\pi(s)$ 는 상태 s 에서 시작해서 정책 π 를 따라 상태를 전이해 나갈 때, 예상되는 보상 총합(expected total sum of rewards)이다. 즉, 벨류 함수의 값은 다음과 같이 계산되며,

$$\begin{aligned} V^\pi(s_0) &= r(s_0, \pi(s_0)) + \gamma r(s_1, \pi(s_1)) + \gamma^2 r(s_2, \pi(s_2)) + \dots \\ &= r(s_0, \pi(s_0)) + \gamma V^\pi(s_1) \end{aligned}$$

최적 벨류 함수(optimal value function) $V^*(s)$ 는 다음 수식과 같이 정의된다.

$$V^*(s) = \max_{\pi} V^{\pi}(s)$$


즉 $V^*(s)$ 는 가장 최적의 정책을 따를 때 얻을 수 있는 보상 총합이다.

3.3.3.2 학습 및 예측(Learning and Prediction)

위 절과 같이 정의된 MDP를 기반으로 강화 학습 기법인 Q-learning을 이용해서 $Q(s,a)$ 를 학습하였다[20]. $Q(s,a)$ 는 일반적으로 다음 수식과 같이 정의된다.

$$\begin{aligned} Q(s,a) &= r(s,a) + \gamma V^*(s') \\ &= r(s,a) + \gamma \max_{a'} Q(s',a') \end{aligned}$$

$Q(s,a)$ 값은 상태 s 에서 행동 a 를 취했을 때 얻을 수 있는 추정된 총 보상의 합(estimated sum of total reward)이다.. 본 연구에서 정형화한 MDP에서는 $Q(s_t, a_t)$ 값은 이전 평점 s_t 에서 행동 a_t 을 취해 다음 평점을 s_{t+1} 로 매겼을 때, 기본이 되는 예측기가 상태 s_{t+2} 에 내린 예측 평점보다 얼마만큼 높게 평점을 매겼느냐 또는 낮게 평가를 내렸느냐를 나타낸다. 이를 그림 3-12에 도시하였다.



<그림 3-12> 벨류 함수 Q의 정의

이때 Q-learning은 $Q(s_t, a_t)$ 는 s_t 에서 s_{t+1} 로의 전이가 s_{t+2} 의 결정에 미치는 영향을 학습한다. Q-learning의 업데이트 규칙은 아래 수식과 같다.

$$\Delta Q(s,a) = \alpha [r(s,a) + \max_{a'} Q(s',a') - Q(s,a)]$$

$Q(s,a)$ 는 예전의 총 보상의 합의 추정 값이고, $r(s,a) + \max_{a'} Q(s',a')$ 는 새로운 총 보상의 합의 추정 값을 의미한다. 상태 s 에서 취할 수 있는 행동의 수는 $|S|$ 이므로 $Q(s,a)$ 는 $|S||X||S|$ 크기의 테이블이 된다. 학습을 위해 각 유저의 평점 데이터가 사용되는데 이를 위해 평점 행렬 $V \in R^{N \times M}$ 를 다음 그림 3-13과 같이 구성한다.

그림에서, $s_j^{(i)}$ 는 유저 i 가 j 번째 본 영화에 대해 내린 평점이다. 평점 행렬 $X \in R^{N \times M}$ 에서 추가적으로 영화에 대한 평점을 매긴 시간 데이터가 있으면 위의 훈련 데이터를 쉽게 구성할 수 있다. 각 유저의 일련의 평점 시퀀스는 하나의 에피소드(episode)로 볼 수 있다. 이 일련의 에피소드들이 Q-learning의 훈련 데이터가 된다.

$$\begin{array}{c}
s_1^{(1)} \xrightarrow{a_1^{(1)}} s_2^{(1)} \xrightarrow{a_2^{(1)}} s_3^{(1)} \xrightarrow{a_3^{(1)}} \dots \xrightarrow{a_{T_1-1}^{(1)}} s_{T_1}^{(1)} \\
s_1^{(2)} \xrightarrow{a_1^{(2)}} s_2^{(2)} \xrightarrow{a_2^{(2)}} s_3^{(2)} \xrightarrow{a_3^{(2)}} \dots \xrightarrow{a_{T_2-1}^{(2)}} s_{T_2}^{(2)} \\
\vdots \\
s_1^{(m)} \xrightarrow{a_1^{(m)}} s_2^{(m)} \xrightarrow{a_2^{(m)}} s_3^{(m)} \xrightarrow{a_3^{(m)}} \dots \xrightarrow{a_{T_m-1}^{(m)}} s_{T_m}^{(m)}
\end{array}$$

<그림 3-13> Q-learning을 위한 에피소드 구성

훈련 데이터 집합이 완성되면 Q-learning 알고리즘을 통해 $Q(s,a)$ 을 학습할 수 있다. 전체적인 알고리즘은 알고리즘 5에 기술하였다.

| $\text{Train}(\alpha, \gamma)$ |
|---|
| Output: $Q(s,a)$ |
| 1. Initialize $Q(s,a)$ |
| 2. Convert $V \in R^{N \times M}$ to training episode set |
| 3. For each user $i = 1 : N$ |
| 4. For each movie $j = 1 : T_i$ seen by i |
| 5. $r(s_j^{(i)}, a_j^{(i)}) = s_{j+2}^{(i)} - \text{predict}(i, j)$ |
| 6. $Q(s,a) = Q(s,a) + \Delta Q(s,a)$ |

<알고리즘 5> 추천 시스템의 강화 학습 알고리즘

위 Train 알고리즘은 정해주어야 할 매개변수가 두 개가 있다. γ 는 MDP의 5가지 구성 요소 중에 하나인 할인율이고 α 는 학습율이다. 실험을 통해 적당한 값을 정해주어야 한다. 실험 결과를 기술하는 다음 절에서 이를 보인다.

이렇게, 위에서 어떻게 추천 시스템을 강화 학습을 사용하여 학습할 수 있는지 보였는데 추가적으로 이 학습한 시스템을 통해 어떻게 예측을 수행할 수 있는지를 정의할 수 있다. 이를 정의하면, 검증 데이터를 사용하여 실제 평점과 예측 평점과의 차이를 계산한 후 성능을 평가할 수 있다. 만약 상태를 평점으로 정의한다면, 유저 i 가 j 번째 본 영화에 대한 예측 평점 $p_j^{(i)}$ 은 아래 수식과 같이 계산되어진다.

$$p_j^{(i)} = \text{predict}(i, j) + Q(s_{j-2}^{(i)}, a_{j-2}^{(i)})$$

이전 절에서 만약 상태를 영화의 평점으로 정의한다면, $r(s_j^{(i)}, a_j^{(i)})$ 를 계산하는데 다음 상태 $s_{j+1}^{(i)}$ 가 아니라 다음다음 상태 $s_{j+2}^{(i)}$ 를 이용하는 이유는 앞에서 정한 상태와 행동의 정의와 관련이 깊다. 만약 $s_{j+1}^{(i)}$ 을 사용한다면 예측 평점 $p_j^{(i)}$ 은 다음 수식과 된다.

$$p_j^{(i)} = \text{predict}(i, j) + Q(s_{j-1}^{(i)}, a_{j-1}^{(i)})$$

하지만 위 수식에서 $Q(s_{j-1}^{(i)}, a_{j-1}^{(i)})$ 는 예측하고자 하는 시점에서는 알 수 없다. 왜냐하면 $a_{j-1}^{(i)}$ 를 알기 위해선, 현재 상태 $s_j^{(i)}$ 를 알아야 하는데, 상태를 영화의 평점으로 정의하였기 때문에 $s_j^{(i)}$ 는 바로 영화의 평점 즉 우리가 추측하고자 하는 답이 되어 이용할 수 없다.

3.3.3.3 실험 데이터

데이터 집합으로는 MovieLens 데이터를 사용하였다[15]. Netflix 데이터 대신 MovieLens를 사용한 이유는 MovieLens 데이터는 평점의 시간 데이터가 초단위로 되어 있기 때문이다. Netflix 데이터는 유저가 평점을 매긴 시간이 일 단위로 되어 있기 때문에 하루에 다수의 영화의 평점을 매겼을 경우, 그 순서를 알 수 없었다. 평점을 매긴 순서는 본 연구에서 제안한 알고리즘의 중요한 조건 중에 하나이기 때문에 MovieLens 데이터를 사용하였다. MovieLens 데이터는 71,567명의 유저와 10,681개의 영화에 대해서 10,000,054개의 평점들로 이루어져 있는 데이터를 사용하였다.

그림 3-14와 같이 각 유저의 영화 평점 데이터를 시간 순으로 정렬한다. 이때 각 유저마다 평점을 매긴 영화의 수는 유저마다 다르다. 먼저 본 영화에 대한 평점 80%를 훈련 데이터 집합으로 사용하고 나머지 20%를 테스트 데이터 집합으로 사용하였다. MovieLens 렌즈 데이터는 0.5점부터 0.5 간격으로 5점까지의 평점으로 이루어져 있다.

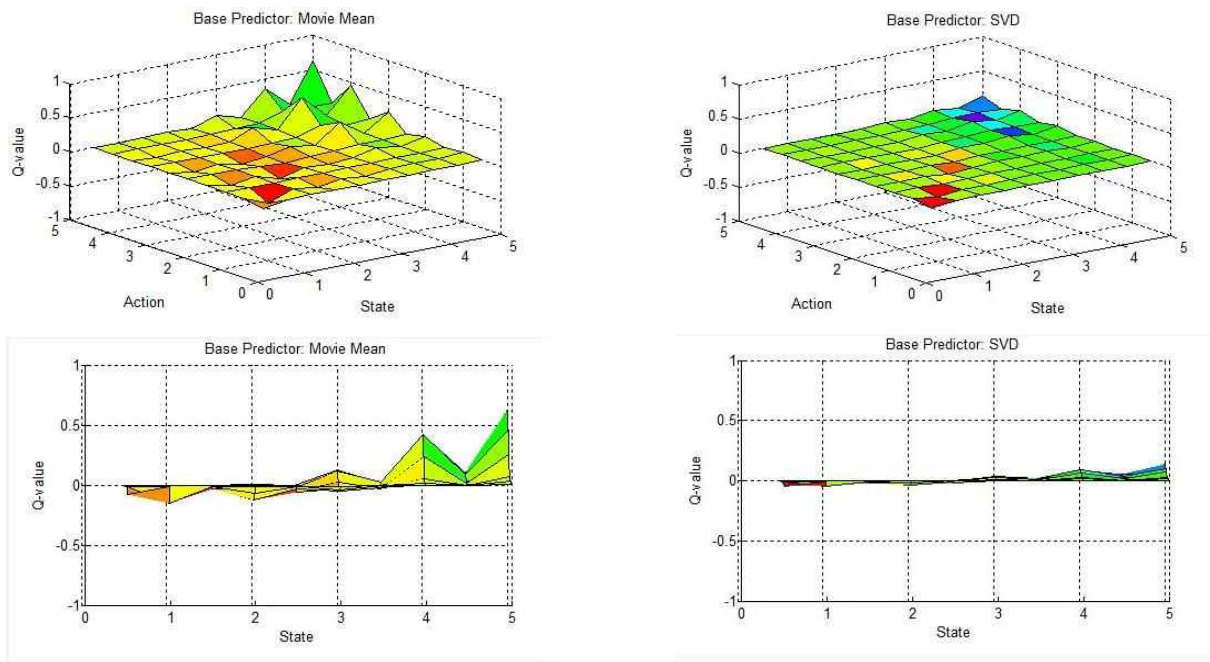


<그림 3-14> 데이터 구성

3.3.3.4 실험 및 분석

평점을 상태(state)로 본다면, 0.5에서 5점까지의 평점을 각각의 상태로 보고 총 10개의 상태로 볼 수 있다. 이 때 제안 알고리즘으로 학습해야 할 $Q(s,a)$ 는 10×10 크기의 테이블이 된다. 그림 3-15에 제안 알고리즘으로 학습된 $Q(s,a)$ 를 도시하였다. x, y, z 는 각각 상태, 행동, Q 값을 의미한다. 그림 3-15의 왼쪽 그림은 전장에서 언급한, 예측할 때 사용되는 수식의 $predictor$ 를 각 영화의 평균으로 했을 때의 $Q(s,a)$ 이고, 오른쪽 그림은 $predictor$ 를 SVD++로 했을 때의 $Q(s,a)$ 의 모습이다. 그리고 그림의 아래쪽 그림들은 각각 위의 그래프를 옆에서 본 모습이다. $predictor$ 를 영화 평균으로 했을 때, $predictor$ 를 SVD++로 했을 때보다 각 상태 변이 시 Q 값의 변화가 더 큼을 알 수 있다. $Q(s,a)$ 의 이 실험 결과는 $t-2$ 번째 본 영화와 $t-1$ 번째 영화의 평점이 t 번째 평점을 매길 영화에 대해서 미치는 영향을 정량적으로 보여준다. 예를 들어, 그림 3-15의 왼쪽 그림에서 보듯이 $Q(s,a)$ 는 유저가 $t-2$ 번째 본 영화에 대해서 평점 5점을 매기고 다시 $t-1$ 번째 본 영화에 대해서 평점 5점을 매겼을 때, t 번째 본 영화에 대해서 그 영화에 대한 평균 평점보다 약 0.6점 가량 더

높은 평점을 매기는 경향이 있다는 것을 알려준다.



<그림 3-15> 상태-행동-Q 값의 관계 그래프 (왼쪽: predictor가 영화평균, 오른쪽: predictor가 SVD++)

다음 실험으로 각 기본 예측기에 대해 제안 알고리즘을 적용하였을 때 성능 향상을 비교하여 보았다. 5.1절에서 설명한 대로 분리한 테스트 데이터에 대해 기본 예측기(영화평균, SVD, SVD++)과 기본예측기+제안알고리즘(RLCF)의 RMSE 성능을 비교해보았다. SVD, SVD++ 알고리즘 특성의 차원은 10으로 설정하였다. 실험에 사용된 모든 알고리즘은 C로 구현하였고 모든 실험은 쿼드코어 2.4Ghz RAM 8GB PC에서 실험하였는데, 제안 알고리즘의 경우 1분 이내에 학습, 예측, 평가가 완료되었다.

제안 알고리즘은 정해주어야 할 두 가지 파라미터가 있다. Q-learning의 학습율 α 와 할인율 γ 이다. 최적의 파라미터를 찾기 위해, 예측 수식의 $predictor(i,j)$ 를 영화 j 의 평균 평점으로 정하고 α 와 γ 를 변화시켜 가면서 RMSE를 측정하였다. 실험을 통해 기본 예측기를 영화평균으로 할 경우 $\alpha=0.5$, $\gamma=0.000003$ 에서 가장 좋은 성능을 보여줬고, SVD로 할 경우 $\alpha=0.5$, $\gamma=0.000006$, SVD++으로 할 경우 $\alpha=0.65$, $\gamma=0.000006$ 에서 가장 좋은 성능을 보였다. 이 파라미터를 가지고 성능 비교를 한 결과는 표 3-8에 나타내었다.

<표 3-8> 강화 학습된 추천 시스템의 성능 평가

| Algorithm | Base RMSE | Proposed RMSE | Improvement |
|-------------|-----------|---------------|-------------|
| Movie Means | 0.9381 | 0.9109 | 0.0272 |
| SVD | 0.8014 | 0.7970 | 0.0044 |
| SVD++ | 0.8000 | 0.7954 | 0.0046 |

첫 번째 실험인 기본 예측기를 영화 평균으로 할 경우 0.0272의 RMSE 성능 향상이 있었고, 두 번째 실험인 기본 예측기를 SVD로 할 경우 0.0044의 RMSE 성능 향상, SVD++으로 할 경우 0.0046의 RMSE 성능 향상이

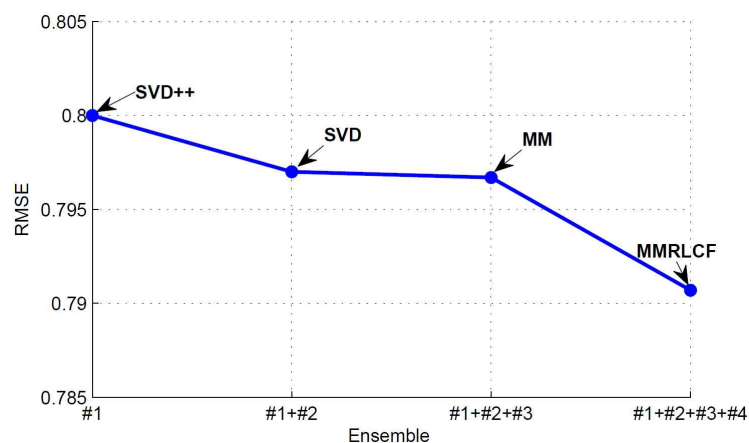
있었다. 첫 번째 실험의 경우, 영화 평균에 비해 큰 폭의 성능향상을 보였기 때문에 제안 알고리즘이 아이템에 대한 평가의 순서가 사용자의 결정에 끼치는 영향을 의미 있게 학습해 냈다고 볼 수 있다. 또 두 번째와 세 번째 실험의 경우 현재 협력적 여과 분야에서 단일 알고리즘 중 가장 효율적이라고 알려져 있는 SVD와 SVD++의 성능을 더욱 올려놓았다. 이는 제안 알고리즘이 SVD와 SVD++이 학습할 수 없는 평점 데이터의 순차적인 연관 관계를 추가적으로 학습할 수 있게 해준다는 것을 의미한다. 본 연구의 주제와는 벗어나지만, Netflix 대회에서 가장 각광받는 예측기의 앙상블 기법도 좋다고 알려진 단일 알고리즘을 앙상블 예측기에 하나씩 추가할 때, 약 0.0010 정도의 향상도 힘들기 때문에, 0.0046 정도의 성능 향상은 의미가 있다고 할 수 있다.

3.3.3.5 앙상블 실험

예측기의 앙상블의 목적은 단일 예측기들의 약점들을 서로 보완하는 것이다. 예측기마다 볼 수 있는 데이터의 양상이 다르게 때문에 예측기의 앙상블을 통해서 더욱 완벽한 하나의 앙상블 예측기를 만들 가능성이 있다. 제안한 강화 학습 사용 알고리즘은 기존 여타의 단일 알고리즘이 쓰지 않는 평점의 순서를 학습해 내기 때문에 기본 예측기로 앙상블 예측기를 쓸 경우 앙상블 예측기의 정확도를 더욱 높일 수 있을 것으로 기대되었다. 그리하여 기존 알고리즘에 추가로 앙상블할 때 의미 있는 성능 향상이 있는지 살펴보았다. 표 3-9는 앙상블의 결과를 정리한 것이고, 그림 3-16은 이를 그래프로 나타낸 것이다. 표와 그림에서 MMRLCF는 강화 학습의 *predictor*를 영화평균평점으로 사용하여 학습한 예측기이다.

<표 3-9> 앙상블의 구성 및 성능

| Ensemble ID | Algorithm | RMSE |
|-------------|-----------------|--------|
| #1 | SVD++ | 0.8000 |
| #2 | SVD | 0.8014 |
| #3 | Movie Means(MM) | 0.9381 |
| #4 | MMRLCF | 0.9109 |
| #1+#2 | Ensemble | 0.7970 |
| #1+#2+#3 | Ensemble | 0.7967 |
| #1+#2+#3+#4 | Ensemble | 0.7907 |



<그림 3-16> 앙상블의 성능 향상 효과

MMRLCF를 앙상블 예측기에 적용했을 때 RMSE 수치는 0.0060만큼 하락하여 성능이 향상되었다(표에서 #1+#2+#3+#4). 비록 단일 예측기로서의 MMRLCF의 성능은 SVD, SVD++에 비해 뛰어나지 않지만, MMRLCF를 추가했을 때의 앙상블 예측기의 성능은 다른 앙상블 예측기보다 높았다. 이는 앞에서 언급한 것처럼, 예측기마다 볼 수 있는 데이터의 양상이 다르게 때문에 앙상블을 통해서 더욱 완벽한 하나의 앙상블 예측기를 만들 가능성이 있음을 실험적으로 보인 것이다.

본 방법은 영화 데이터의 협력적 여과 문제를 강화 학습으로 접근하여 해결하는 방식을 제시한 것으로, 이를 위해 협력적 여과문제를 마르코프 결정 과정으로 사용자의 아이템에 대한 평가의 순서가 사용자의 결정에 끼치는 영향을 수학적으로 모델링하였고, 강화 학습의 가장 대표적인 알고리즘인 Q-learning을 사용해서 평가의 순서의 연관 관계를 학습하였다. 실험을 통해서 실제로 평가의 순서가 평가에 미치는 영향이 있다는 것을 검증하였다. 이는 본 연구팀이 아는 바로, 추천 시스템의 협력적 여과 분야에서 처음으로 강화 학습 기법을 적용한 것이다. 그리하여 본 연구가 연구자들의 협력적 여과 및 여타 추천 시스템의 연구에 많은 영감을 줄 것을 기대한다.

4. 목표 달성도 및 관련 분야에의 기여도

| 연구개발목표 | 달성도 | 달성도 설명 및 기여도 평가 |
|-----------------------------|-----|---|
| 데이터 수집 및 전처리 | 100 | Netflix 데이터를 이용하여 시스템의 성능을 검증하였는데, 이를 손쉽게 사용하기 위해 전처리 과정을 거쳤으며 C와 Matlab에서 사용 가능한 형태로 바꾸어서 이후 관련 연구에 쉽게 사용할 수 있도록 하였다. 그리고 콘텐츠 기반 SVD 추천 시스템을 개발할 때, MovieLens 데이터에 네이버, 다음의 영화 정보 데이터베이스에서 얻은 데이터를 추가하였는데, 이를 위해 자동화된 쿼리 및 데이터 생성 작업을 수행하는 소프트웨어를 개발하였다. 이 소프트웨어 또한 이후 다른 연구에서 필요할 때 쉽게 사용할 수 있으므로 기술 발전에 기여할 수 있다. |
| 단일 추천 알고리즘 구현 | 100 | 앙상블 추천 시스템의 기반이 되는 예측기들을 구현하고 이들을 하나의 시스템에 통합함으로써, 연구자들이 한눈에 여러 알고리즘을 살펴보는 것이 가능해졌다. 그리고 추가로 콘텐츠 기반 SVD 알고리즘, 강화 학습을 이용한 추천 시스템 최적화 알고리즘을 개발하였는데 특히 후자의 추천 시스템은 독창성이 있으며 다른 강화 학습을 사용한 연구 및 추천 시스템 최적화 관련 응용에 많은 영감을 줄 것이라 기대된다. |
| 추천 시스템 범용 라이브러리 클래스 및 UI 설계 | 100 | 새로운 알고리즘의 추가가 용이한 범용 라이브러리 클래스와 사용하기 쉬운 UI를 Matlab과 C를 기반으로 개발함으로써 이후에 개별 예측기를 추가하여 실험하거나 가설 검증에 유용하게 사용할 수 있다. |
| 추천 시스템 라이브러리 코어 제작 | 70 | 구현된 단일 추천 시스템들을 라이브러리에 추가 중인데, 이 작업이 완료되고 또한 문서 작업이 완료되면 추후 기술 이전, 타 연구에서의 사용 등에 큰 도움이 될 것이라 기대된다. |
| 앙상블 추천 시스템 구현 | 80 | 개발된 단일 추천 시스템을 바탕으로 앙상블 추천 시스템을 구성하였는데, 실제 구현된 코드와 라이브러리를 통해 다른 관련 연구를 수행하고자 할 때 가이드라인을 제시할 수 있고 또한 앙상블 연구에서 이미 학계에 발표된 추천 시스템을 구현하는 수고를 절약할 수 있다. |

5. 연구결과의 활용계획

연구결과가 Netflix competition 기준 국내에서 연구된 추천 시스템 중에서는 가장 높은 성능을 보유하고 있지만 아직 세계적인 수준에는 미흡하기 때문에 추가 연구를 통해 성능 개선을 꾀할 수 있다. 먼저, 단일 시스템의 성능을 향상시키기 위해서 각각 다음과 같은 추가 연구를 수행할 수 있다.

| | |
|-------------------------------------|---|
| <p>컨텐츠 기반 SVD 추천 시스템</p> | <ol style="list-style-type: none"> 1. 데이터의 수집: 현재 웹 컨텐츠 사이트를 통해 생성한 컨텐츠 데이터는 전체 행렬에서 0.001%의 관계만이 관찰된다. 이렇게 비율이 작은 정보를 SVD를 통해 학습할 경우 반복된 학습을 통해 과적합 문제를 겪는다. 이를 위해서 엄선된 컨텐츠 데이터를 수집하고, 생성한 컨텐츠 데이터를 전처리를 통해 데이터의 희소성을 줄여줄 필요가 있다. 2. 계산 최적화: 학습 단계에서 한 영화에 대해 연결된 컨텐츠의 특성 벡터를 모두 학습해야 하므로, 계산량과 계산 시간이 컨텐츠 데이터의 양에 따라 기하급수적으로 증가한다. 이러한 점을 수정하기 위해 학습 및 예측에 사용되는 컨텐츠의 수를 제한할 필요가 있다. 이에 대한 추가 연구가 필요하다. |
| <p>강화 학습을 이용한 추천 시스템 최적화</p> | <ol style="list-style-type: none"> 1. 문제 정의 확장: 협력적 여과를 마르코프 결정 과정으로 모델링할 때, 상태를 평점뿐만 아니라 다른 것들로 정의할 수 있다. 예를 들어, 평점을 매기고자 하는 영화의 장르나, 그 영화를 감상한 계절, 그 영화에 달린 태그들이 그것이다. 상태를 평점으로 정의했을 경우 본문에서 기술한 것처럼 s_t를 예측할 때 s_{t-2}에서 s_{t-1}로의 상태 전이를 이용하지만, 위의 예시된 정보를 상태로 정의했을 시, s_t를 예측할 때 바로 s_{t-1}에서 s_t로의 상태 전이의 정보를 이용할 수 있다. 또한 위의 정보를 상태로 정의했을 때 액션 영화를 본 후 멜로 영화를 봤을 때 평가에 미치는 영향 등을 학습해 낼 수 있다. 이렇게 상태를 다르게 정의하여 시스템을 구성함으로써, 또 앙상블에 추가함으로써 성능 향상을 기대할 수 있다. 2. 제안 알고리즘의 변화: 제안 알고리즘에 쓰이는 기본 예측기 대신 정확도가 높은 앙상블 예측기를 사용할 수 있다. 이를 통해 더 높은 예측 정확도를 기대할 수 있다. |

연구결과를 직접적으로 사용함으로써 관련 산업 또는 연구에 응용될 수 있다. 예를 들어, 데이터를 영화 데이터가 아닌 다른 데이터를 사용함으로써 영화가 아닌 다른 분야에서의 추천 시스템 개발이 가능하다. 양질의 도서 데이터베이스, 쇼핑 데이터베이스, 소셜 네트워크 데이터 등을 사용함으로써 산업면에서 유용한 추천 시스템을 개발할 수 있으며 또 추가 연구의 문을 개방할 수 있다.

또는 예측기를 앙상블할 때 다른 예측기를 추가, 변경하거나 예측기의 조합을 변경함으로써 다양한 형태의 연구가 가능한데, 이러한 작업을 계속함으로써 성능이 좋은 앙상블의 조합을 찾아낼 수 있고 이는 학문적으로나 산업적으로나 유용한 결과물이 된다.

강화 학습은 시스템 최적화에 유용한 도구이지만 문제 정형화 및 검증 절차를 구성하는 것이 어려워 제한적

인 영역에서 사용되고 있고, 추천 시스템의 최적화 및 응용에는 아직 사용된 예가 없다. 이 연구의 예를 통해 강화 학습을 이용하는 방법을 습득할 수 있으며 타 연구에도 어떤 학습 알고리즘을 더 최적화하는 방법으로써 응용될 수 있다.

기업화 추진을 위해서는 먼저 연구결과를 정리하고, 우수성을 보여줄 수 있는 논문 게재가 필요하다. 연구결과 정리는 라이브러리 및 코드 최적화 및 인터페이스 단순화, 코드 레벨의 설명문서 제작, 활용 설명서 제작 등이 포함된다. 그리고 영화뿐만 아니라 다른 영역에서의 데이터 획득 및 처리, 성능 검증을 통해 개발한 시스템이 범용성이 있음을 보이고 영화가 아닌 다른 쪽에서도 사용할 수 있음을 보여야 한다.

6. 연구과정에서 수집한 해외과학기술정보

연구결과의 우수성 검증 및 타 시스템과의 비교를 수월히 하기 위해서 Netflix와 MovieLens의 공개 데이터를 사용하였다. 또한 이 두 데이터를 사용하는 관련 연구들에 대한 정보(논문, 발표 자료, 구현 소스 코드)를 수집하였다. 논문 목록은 아래 참고 문헌 항목에 기술하였으며 각 논문에서 기술하는 저자 홈페이지 또는 관련 시스템 정보를 참조하여 발표 자료 및 구현 소스 코드 등을 획득하였다.

7. 주관연구책임자(공동연구원) 대표적 연구 실적

| 번호 | 논문명/특허명/기타 | 소속기관명 | 역할 | 논문게재지/ 특허등록국가 | 논문게재일 /특허등록일 | 특기사항 (SCI여부) |
|----|---|-------|------|--|-----------------|-----------------|
| 1 | Feature Subset Selection based on Bio-Inspired Algorithm | 서강대학교 | 교신저자 | Journal of Information Science and Engineering (대만) | 게재예정 | SCIE (IF=0.32) |
| 2 | Genetic Algorithm-based Dynamic Vehicle Route Search using Car-to-Car Communication | 서강대학교 | 교신저자 | Advances in Electrical and Computer Engineering (루마니아) | 2010.11.01 | SCIE (IF=0.509) |
| 3 | A Hierarchical Bitmap Indexing Method for Similarity Search in High-Dimensional Multimedia Databases | 서강대학교 | 참여저자 | Journal of Information Science and Engineering(대만) | 2010.03.01 | SCIE (IF=0.32) |
| 4 | Walk-Weighted Subsequence Kernels for Protein-Protein Interaction Extraction | 서강대학교 | 교신저자 | BMC Bioinformatics(영국) | 2010.02.01 | SCIE (IF=3.43) |
| 5 | Methods and Apparatus for Scanning, Personalizing, and Casting Multimedia Data Streams via a Communication Network and Television | 서강대학교 | 교신저자 | 특허 (미국) | 2011.01.11 | 국제특허 |

※ 대표 연구실적은 총 연구기간 중 발표된 대표적 연구실적(논문, 특허 등)을 5건 이내로 기재

- 게재완료된 실적(논문 등)을 기재하는 것이 원칙이며, 불가피한 경우 게재예정인 사실도 포함
- ※ 소속기관명 : 연구 성과 발표 시 소속된 기관명을 기재
- ※ 역할 : 논문의 경우 만 작성하며 제1저자, 교신저자, 참여저자 중 선택하여 기재
- ※ 특허 등록 국가 : 특허를 등록한 국가명을 한글로 기재(예시, 대한민국, 미국, 일본 등)
- ※ 특기사항에는 인용 횟수나 우수논문수상 등과 같이 특별히 기술할 필요가 있는 사항을 기재
- ※ 상기의 대표적 논문 및 특허 등록에 대한 내용은 『별첨1 : 대표 연구 업적』 서식에 요약문 작성

8. 참고 문헌

- [1] Resnick, P., Iacovou, N., Suchak, M., Berstrom, P. and Riedl, J., "Grouplens: An Open Architecture for Collaborative Filtering of Netnews", Proceedings of the ACM Conference on Computer Supported Cooperative Work, pp. 175-186, 1994.
- [2] NetRatings, <http://www.nielsen-netratings.com/news.jsp>
- [3] Wall Street Journal, <http://online.wsj.com/public/us/>
- [4] Amazon, <http://www.Amazon.com>
- [5] Netflix, <http://www.netflix.com>
- [6] 싸이월드 뮤직, <http://music.cyworld.com>
- [7] Netflix Prize, <http://www.netflixprize.com>
- [8] <http://www.research.att.com/~volinsky/netflix/>
- [9] R. Bell and Y. Koren, "Improved Neighborhood-based Collaborative Filtering", KDD-Cup and Workshop, ACM press, 2007.
- [10] R. Salakhutdinov, A. Mnih and G. Hinton, "Restricted Boltzmann machines for collaborative Filtering", Proceedings of the 24th International Conference on Machine Learning (ICML'07), 2007.
- [11] Yehuda Koren, Robert Bell and Chris Volinsky, "Matrix Factorization Techniques for Recommender System", IEEE Computer, Vol.42, Issue:8, pp.30-37, 2009.
- [12] Simon Funk, "Netflix Update: Try This At home", <http://sifter.org/~simon/journal/20061211.html>, 2006.
- [13] A. Paterek, "Improving regularized singular value decomposition for collaborative Filtering", KDD-Cup and Workshop, ACM press, 2007.
- [14] James Salter and Nick Antonopoulos, "CinemaScreen Recommender Agent: Combining Collaborative and Content-Based Filtering", IEEE Intelligent System, Vol.21, Issue:1, pp.35-41, 2006.
- [15] MovieLens, <http://www.movielens.org>
- [16] Naver API, <http://dev.naver.com/openapi/apis/data/movie>
- [17] Daum API, <http://dna.daum.net/apis/contents/movie>
- [18] Wikipedia, Reinforcement Learning", http://en.wikipedia.org/wiki/Reinforcement_learning
- [19] R. Bellman. "A Markovian Decision Process", Journal of Mathematics and Mechanics 6, 1957.
- [20] Watkins, C.J.C.H. "Learning from Delayed Rewards", PhD thesis, Cambridge University, Cambridge, England, 1989.

9. 연구 성과

| | | | | | |
|------|--------------|-------|----------------------|------|-------------|
| 사업명 | 기본연구지원사업 | 연구책임자 | 양지훈 | 주관기관 | 서강대학교 산학협력단 |
| 과제번호 | 2009-0076594 | 과제명 | 양상블 학습 기반의 추천 시스템 개발 | | |

| 과학기술/학술적 연구성과(단위 : 건) | | | | | | | | | | | | | |
|-----------------------|------|------|------|----------------|--------------|----|-------|----|----|----|----------|------|-----|
| 전문학술지 논문게재 | | | | 초청 강연 실적 | 학술대회 논문발표 | | 지식재산권 | | | | 수상 실적 | 출판실적 | |
| 국내논문 | | 국외논문 | | | 국내 | 국제 | 출원 | | 등록 | | | 저역서 | 보고서 |
| SCI | 비SCI | SCI | 비SCI | | | | 국내 | 국외 | 국내 | 국외 | | | |
| 0 | 1 | 0 | 0 | 1 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |

| 인력양성 및 연구시설(단위 : 명,건) | | | | | | | |
|-----------------------|----|----------|----|----|----|------|-------|
| 학위배출 | | 국내외 연수지원 | | | | 산학강좌 | 연구기자재 |
| 박사 | 석사 | 장기 | | 단기 | | | |
| | | 국내 | 국외 | 국내 | 국외 | | |
| 0 | 3 | 0 | 0 | 0 | 0 | 0 | 0 |

| 국제협력(단위 :명,건) | | | | | | |
|---------------|---------------|--------|--------|--------|--------|----|
| 과학자교류 | | 국제협력기반 | | | 학술회의개최 | |
| 국내과학자 해외파견 | 외국과학자 국내유치 | MOU체결 | 국제공동연구 | 국제사업참여 | 국내 | 국제 |
| 0 | 0 | 0 | 0 | 0 | 0 | 0 |

| 산업지원 및 연구성과 활용(단위 : 건) | | | | | |
|------------------------|------|------|------------------------|--------|-------|
| 기술확산 | | | 연구성과활용(사업화 및 후속연구과제 등) | | |
| 기술이전 | 기술지도 | 기술평가 | 후속연구추진 | 사업화추진중 | 사업화완료 |
| 0 | 1 | 0 | 0 | 0 | 0 |

| 전문학술지 논문게재 성과정보 | | | | | | | | | | | |
|-----------------|----------|-----------------------------|---------------------------------|--------|------------|-------|---------------|------------|----|--------------------|-------------|
| 과제 번호 | 게재 연월 | 논문제목 | 총저자명 | 출 처 | 학술 지명 | 권(호) | 학술 지 구분 | SCI 여부 | IF | 국제공동 연구 논문여부 | 기 여 도 |
| 2009-0076594 | 2010.04 | 분산 유전 알고리즘에서 자동 마이그레이션 조절방법 | 나용찬[서강대학교]/이현정[삼성전자]/양지훈[서강대학교] | 직접입력 | 정보처리학회논문지B | 17(2) | 국내 | SCI 미등재 | | 아니오 | 60% |

| 국제학술대회 초청강연실적 성과정보 | | | | | |
|--------------------|----------|--|---------|---|------|
| 과제번호 | 발표 연월 | 학술대회명 | 발표 자 | 강연주제 | 개최국 |
| 2009-0076594 | 2010.07 | IEEE International Symposium on Industrial Electronics | | Distributed Bayesian Network Structure Learning | 이탈리아 |

| 학위배출인력 성과정보 | | | | | | | |
|--------------|--------|------|-------|----|----|----|----|
| 과제번호 | 학위취득연월 | 학위구분 | 학위취득자 | | | | 진로 |
| | | | 성명 | 성별 | 대학 | 학과 | |
| 2009-0076594 | | | 오현진 | 남 | | | |
| 2009-0076594 | | | 이정규 | 남 | | | |
| 2009-0076594 | | | 김상화 | 남 | | | |

| 기술확산 성과정보 | | | | | | | |
|--------------|---------|--------|---------|----------------------|------------|------|---------|
| 과제번호 | 시행연월 | 기술확산구분 | 대상기술명칭 | 내용 | 업체명 | 업체유형 | 활용형태 |
| 2009-0076594 | 2009 05 | 기술지도 | 영화추천시스템 | 다수의 추천알고리즘 소개, 구현 지도 | (주)엠엔엘 솔루션 | 중소기업 | 사업화 추진중 |

10. 기타사항(중요 연구 변경사항 등)

※ 기타 필요한 사항을 기술

[별첨1]

〈 대표 연구 성과 〉

| 대표연구업적 요약문 | | | |
|------------------------|--|------|---|
| 연구업적 제목 | Feature Subset Selection based on Bio-Inspired Algorithm | | |
| 연구업적 유형 | 학술지 게재논문(O) 특허() 저서() 역서() | | |
| 주관연구책임자 또는 공동연구원 성명 | 양지훈 | 참여자수 | 5 |

▣ 초록(abstract) 또는 요약문

Many feature subset selection algorithms have been proposed and discussed for years. However, the problem of finding the optimal feature subset from full data still remains to be a difficult problem. In this paper, we propose novel methods to find the relevant feature subset by using biologically-inspired algorithms such as Genetic Algorithm and Particle Swarm Optimization. We also propose a variant of the approach considering the significance of each feature. We verified the performance of the proposed methods by experiments with various real-world datasets. Our feature selection methods based on the biologically-inspired algorithms produced better performance than other methods in terms of the classification accuracy. In particular, the modified method considering feature significance demonstrated even more improved performance in the evolution speed as well as the classification accuracy.

□ 논문

- 게재학술지명: Journal of Information Science and Engineering(대만)
- 게재년월일: 2011년 게재예정
- Impact Factor: 0.32
- 참여자의 역할: 연구책임자

☐ 대표연구업적과 관련된 연구과제가 있는 경우 과제개요 기술

- 사업명: 지식경제부 전략기술개발사업
- 과제명: Scalable BNP용 미들웨어 개발

| 대표연구업적 요약문 | | | |
|---------------------|---|------|---|
| 연구업적 제목 | Genetic Algorithm-based Dynamic Vehicle Route Search using Car-to-Car Communication | | |
| 연구업적 유형 | 학술지게재논문(O) 특허() 저서() 역서() | | |
| 주관연구책임자 또는 공동연구원 성명 | 양지훈 | 참여자수 | 6 |

■ 초록(abstract) 또는 요약문

Suggesting more efficient driving routes generate benefits not only for individuals by saving commute time, but also for society as a whole by reducing accident rates and social costs by lessening traffic congestion. In this paper, we suggest a new route search algorithm based on a genetic algorithm which is more easily installable into mutually communicating car navigation systems, and validate its usefulness through experiments reflecting real-world situations. The proposed algorithm is capable of searching alternative routes dynamically in unexpected events of system malfunctioning or traffic slow-downs due to accidents. Experimental results demonstrate that our algorithm searches the best route more efficiently and evolves with universal adaptability.

■ 논문

- 게재학술지명: Advances in Electrical and Computer Engineering(루마니아)
- 게재년월일: 2010.11.01
- Impact Factor: 0.509
- 참여자의 역할: 연구책임자

■ 대표연구업적과 관련된 연구과제가 있는 경우 과제개요 기술

- 사업명: 지식경제부 전략기술개발사업
- 과제명: Scalable BNP용 미들웨어 개발

| 대표연구업적 요약문 | | | |
|---------------------|--|------|---|
| 연구업적 제목 | A Hierarchical Bitmap Indexing Method for Similarity Search in High-Dimensional Multimedia Databases | | |
| 연구업적 유형 | 학술지게재논문(O) 특허() 저서() 역서() | | |
| 주관연구책임자 또는 공동연구원 성명 | 남종호(공동연구: 양지훈) | 참여자수 | 4 |

■ 초록(abstract) 또는 요약문

This paper proposes an efficient indexing mechanism for similarity search in highdimensional multimedia database that quickly filter-outs the irrelevant objects using a novel indexing structure, called HBI (Hierarchical Bitmap Index). In this bitmap index, the feature (or attribute) value of object at each dimension is represented with a set of two bits each of which indicates whether it is relatively high ('11'), low ('00'), or neither ('01') compared to the feature values of other objects at a hierarchical organized interval. This approximation helps to reduce the CPU time of filtering process because many irrelevant objects could be simply excluded by just XORing the bitmaps of two objects. Upon experimental results, we find that there is an optimal number of bitmaps that keeps the filtering rate as high as possible while keeping the search time as short as possible. Furthermore, we also find that the similarity search using the proposed indexing mechanism is about 2-3 times faster than VA-File while guaranteeing the exact solutions.

■ 논문

- 게재학술지명: Journal of Information Science and Engineering(대만)
- 게재년월일: 2010.03.01
- Impact Factor: 0.32
- 참여자의 역할: 공동연구자

■ 대표연구업적과 관련된 연구과제가 있는 경우 과제개요 기술

- 사업명: 지식경제부 전략기술개발사업
- 과제명: 지능형 네비게이터를 위한 생태계모방 알고리즘 및 멀티미디어 인터페이스 개발

| 대표연구업적 요약문 | | | |
|---------------------|--|------|---|
| 연구업적 제목 | Walk-Weighted Subsequence Kernels for Protein-Protein Interaction Extraction | | |
| 연구업적 유형 | 학술지게재논문(O) 특허() 저서() 역서() | | |
| 주관연구책임자 또는 공동연구원 성명 | 양지훈 | 참여자수 | 4 |

■ 초록(abstract) 또는 요약문

Background

The construction of interaction networks between proteins is central to understanding the underlying biological processes. However, since many useful relations are excluded in databases and remain hidden in raw text, a study on automatic interaction extraction from text is important in bioinformatics field.

Results

Here, we suggest two kinds of kernel methods for genic interaction extraction, considering the structural aspects of sentences. First, we improve our prior dependency kernel by modifying the kernel function so that it can involve various substructures in terms of (1) e-walks, (2) partial match, (3) non-contiguous paths, and (4) different significance of substructures. Second, we propose the walk-weighted subsequence kernel to parameterize non-contiguous syntactic structures as well as semantic roles and lexical features, which makes learning structural aspects from a small amount of training data effective. Furthermore, we distinguish the significances of parameters such as syntactic locality, semantic roles, and lexical features by varying their weights.

Conclusions

We addressed the genic interaction problem with various dependency kernels and suggested various structural kernel scenarios based on the directed shortest dependency path connecting two entities. Consequently, we obtained promising results over genic interaction data sets with the walk-weighted subsequence kernel. The results are compared using automatically parsed third party protein-protein interaction (PPI) data as well as perfectly syntactic labeled PPI data.

■ 논문

- 게재학술지명: BMC Bioinformatics(영국)
- 게재년월일: 2010.02.01
- Impact Factor: 3.43
- 참여자의 역할: 연구책임자

■ 대표연구업적과 관련된 연구과제가 있는 경우 과제개요 기술

- 사업명: 한국학술진흥재단 BK21 사업
- 과제명: 모바일 엔터테인먼트 테크놀러지를 위한 소프트웨어 인력양성팀

| 대표연구업적 요약문 | | | |
|---------------------|---|------|---|
| 연구업적 제목 | Methods and Apparatus for Scanning, Personalizing, and Casting Multimedia Data Streams via a Communication Network and Television | | |
| 연구업적 유형 | 학술지게재논문() 특허(O) 저서() 역서() | | |
| 주관연구책임자 또는 공동연구원 성명 | 양지훈 | 참여자수 | 5 |

■ 초록(abstract) 또는 요약문

A streaming data filtering method and apparatus utilizing users' profiles to deliver streaming data to users is presented. The invention uses context-based cues to extract content from both video and text ontologies. The invention provides novel techniques that semi-automatically generate a media concept hierarchy using hierarchical classifiers for representing text, closed-caption, and video features. This hierarchy is used to classify arrival of real-time news and will also be used to match users' profiles. Moreover, this hierarchy can be dynamically re-organized based upon user changes and arrival of real-time news. Matching a request with respect to a concept hierarchy is more efficient and reliable than searching specific keywords since the views of collected documents are refined as the hierarchy is traversed.

■ 특허

- 등록일: 2011.01.11
- 등록국가: 미국
- 등록번호: US 7,870,279 B2

양식

자체평가 의견서

1. 과제 현황

| | | | | | | |
|---------------------|---------------------------------|-------------------------------|-------------|----|-------------|--------------|
| | | | 과제번호 | | 기재하지 않음 | |
| 사업구분 | 기초연구사업 | | | | | |
| 연구분야 | 기재하지 않음 | | 기재하지 않음 | | 과제구분 | 단위(✓) |
| 사 업 명 | 일반연구자지원사업(기본, 신진, 지역, 여성 중 택 1) | | | | | 주관 |
| 총괄과제 | 기재하지 않음 | | | | 총괄책임자 | 기재하지 않음 |
| 과 제 명 | 양상블 학습 기반의 추천 시스템 개발 | | | | 과제유형 | (기초, 응용, 개발) |
| 연구기관 | 서강대학교 | | | | 연구책임자 | 양지훈 |
| 연구기간 연구비 (천원) | 연차 | 기간 (yyyy.mmdd ~ yyyy.mmdd) | 정부 | 민간 | 계 | |
| | 1차년도 | 2009.05.01 ~ 2010.04.30 | 56,980,000 | | 56,980,000 | |
| | 2차년도 | 2010.05.01 ~ 2011.04.30 | 52,030,000 | | 52,030,000 | |
| | 3차년도 | | | | | |
| | 4차년도 | | | | | |
| | 5차년도 | | | | | |
| | 계(총연구기간) | 24개월 | 109,010,000 | | 109,010,000 | |
| 참여기업 | | | | | | |
| 상 대 국 | | | 상대국연구기관 | | | |

2. 평가일 : 2011. 06. 16

3. 평가자(연구책임자)

| 소속 | 직위 | 성명 |
|--------------|----|-----|
| 서강대학교 컴퓨터공학과 | | 양지훈 |

4. 평가자(연구책임자) 확인

본인은 평가 대상 과제에 대한 연구 결과에 대하여 객관적으로 기술하였으며, 공정하게 평가하였음을
확약하며, 본 자료가 전문가 및 전문기관 평가 시에 기초 자료로 활용되기를 바랍니다.

확 약

양지훈

I. 연구 개발 실적

※ 다음 각 평가 항목에 따라 자체평가한 등급 및 실적을 간략하게 기술(200자 이내)

1. 연구 개발 결과의 우수성 및 창의성

■ 등급 : (아주 우수, 우수, 보통, 미흡, 불량)

아주 우수

제안서에 계획한 추천 시스템을 위하여 20가지 이상의 다양한 방법을 구현하고 성능을 확인하였음. 기존의 방법에서 크게 개선된 독창적인 방법이 구현되었다. (컨텐츠 기반 SVD, 강화 학습을 이용한 추천 시스템 최적화 방법 및 그 앙상블)

2. 연구 개발 결과의 파급 효과

■ 등급 : (아주 우수, 우수, 보통, 미흡, 불량)

아주 우수

본 연구에서 개발, 구현한 방법은 즉시 활용 가능하며 실제로 기반기술을 국내기업체에 이전하였고 향후 사업화를 모색 중이다.

3. 연구 개발 결과에 대한 활용 가능성

■ 등급 : (아주 우수, 우수, 보통, 미흡, 불량)

아주 우수

추천 시스템은 영화뿐만 아니라 서적, 음반을 포함한 기타 여러 분야에서 활용될 수 있으며 Amazon, Netflix와 같이 외국 기술이 잠식하고 있는 현 상황에서 국제경쟁력을 갖추는데 큰 기여를 하리라 본다.

4. 연구 개발 수행 노력의 성실도

■ 등급 : (아주 우수, 우수, 보통, 미흡, 불량)

아주 우수

앞에 기술한 20개 이상의 추천 시스템을 연구하고 이를 통합하는 앙상블 기반 추천 시스템을 구현하여, 이를 방대하고 실제적인 Netflix 데이터에 적용하여 검증하였으며 성능 향상에 노력하는 등 성실하게 연구를 수행하였다. 특히 Netflix 공개 competition에서 국내최고의 성적을 보유하고 있다.

5. 공개 발표된 연구 개발 성과(논문, 지식재산권, 발표회 개최 등)

■ 등급 : (아주 우수, 우수, 보통, 미흡, 불량)

| |
|--|
| <p>우수</p> <p>1차년도에는 개발과 실험에 중점을 두어 논문성과는 다소 미흡하였으며 2차년도의 연구 결과를 정리하여 국내외 논문지에 게재할 예정이다. 한편, 기업체에 기술을 전수 지도하는 등의 중요한 성과를 거두었다. 또한, 본 과제와 직간접적으로 관련된 주제를 기반으로 SCI를 포함한 논문 및 특허를 발표하는 등의 성과도 달성하였다.</p> |
|--|

II. 연구 목표 달성도

| 세부 연구 목표 (연구계획서 상의 목표) | 비중 (%) | 달성도 (%) | 자체평가 |
|---|-----------|------------|--|
| 데이터 수집 및 전처리 (1차년도 목표) | 20 | 100 | 세계에서 가장 크고 신뢰성 있는 Netflix 데이터를 이용하였고, 추가로 시간 및 콘텐츠 자료를 포함한 MovieLens 데이터를 사용하였다. |
| 단일 추천 알고리즘 구현 (1차년도 목표) | 50 | 100 | 20개의 예측기를 구현하였다. 또한 콘텐츠 기반 SVD 알고리즘, 강화 학습을 이용한 SVD 최적화 알고리즘을 개발하였다. |
| 추천 시스템 범용 라이브러리 클래스 및 UI 설계 (1차년도 목표) | 30 | 100 | 새로운 알고리즘의 추가가 용이한 범용 라이브러리 클래스와 사용하기 쉬운 UI를 설계하였다. |
| Extra Work: 추천 시스템 라이브러리 코어 제작 (2차년도 목표) | 0 | 70 | 구현된 단일 추천 시스템들을 라이브러리에 추가중이다. |
| Extra Work: 앙상블 추천 시스템 구현 (2차년도 목표) | 0 | 80 | 개발된 단일 추천 시스템을 바탕으로 앙상블 추천 시스템을 구축하였다. |
| 합계 | 100 | | |

III. 종합 의견

1. 연구 개발 결과에 대한 종합 의견

계획했던 것 보다 많은 알고리즘을 채택, 개발하고 구현하여 우수한 결과를 얻었다고 본다. Netflix competition(이미 종료)에서 세계의 4만명/팀 이상의 참가자 중에서 130위라는 성적을 거두었으며 이는 2009년 현재 Netflix의 성능대비 7%이상의 뛰어난 정확도이다. 강화 학습을 SVD 기반 추천 시스템의 최적화에 적용함으로써 다른 연구자들이 시도하지 않은 방법의 독창적인 추천 시스템을 구현하려 하였고, 앙상블의 결과 다른 추천 시스템과 결합할 때 성능이 향상될 수 있음을 실험적으로 검증하였다. 시스템을 적용할 때 정확도를 높일 수 있는 추가적인 알고리즘을 개발하였다는 것에 큰 의의가 있다.

2. 평가 시 고려할 사항 또는 요구사항

과제와 간접적으로 관련된 다수의 논문 및 특허를 발표하였지만, 연구결과가 직접적으로 반영된 학술지 논문의 작성과 발표에는 연구 종료 후 2~3년 사이의 시간이 필요하다고 생각된다. 현재 연구 결과를 정리하여 국제/국내 학술지에 제출하여 심사 중에 있다.

3. 연구 결과의 활용 방안 및 향후 조치에 대한 의견

우선 기본적인 핵심 알고리즘에 대한 기술을 중소기업에 전수하였고 또 추가로 타 업체에 전수중이다. 또한 이를 바탕으로 추천 시스템의 사업화를 구상 중에 있다. 본 연구의 수행을 통해 이를 지속적으로 개선하고, 다양한 제품에 대한 추천시스템을 개발하여 새로운 사업의 창출에 기여하리라고 기대한다.

IV. 보안성 검토

o 연구책임자의 보안성 검토 의견, 연구기관 자체의 보안성 검토 결과를 기재함

※ 보안성이 필요하다고 판단되는 경우에만 작성함

1. 연구책임자의 의견

2. 연구기관 자체의 검토 결과

※ 협약당사자(산학협력단장 등)의 의견을 기재함